
目录

Introduction	1.1
官方文档	1.2
开发指南	1.2.1
搭建本地集群	1.2.1.1
和 etcd 交互	1.2.1.2
核心 API 参考文档	1.2.1.3
并发 API 参考文档	1.2.1.4
gRPC 网关	1.2.1.5
gRPC 命名和发现	1.2.1.6
试验性的 API 和特性	1.2.1.7
系统限制	1.2.1.8
运维指南	1.2.2
搭建 etcd 集群	1.2.2.1
运行时重配置	1.2.2.1.1
运行时重配置的设计	1.2.2.1.2
搭建 etcd 网关	1.2.2.2
在容器内运行 etcd 集群	1.2.2.3
配置	1.2.2.4
gRPC代理(TBD)	1.2.2.5
L4 网关	1.2.2.6
支持平台	1.2.2.7
硬件推荐(TBD)	1.2.2.8
性能评测	1.2.2.9
调优(TBD)	1.2.2.10
安全模式	1.2.2.11
基于角色的访问控制(TBD)	1.2.2.12
常见问题(TBD)	1.2.2.13
监控(TBD)	1.2.2.14
维护	1.2.2.15
理解失败	1.2.2.16

灾难恢复	1.2.2.17
版本	1.2.2.18
学习	1.2.3
为什么是etcd	1.2.3.1
理解数据模型	1.2.3.2
理解API	1.2.3.3
术语	1.2.3.4
API保证	1.2.3.5
认证子系统(TBD)	1.2.3.6
核心 API 参考文档	1.3
KV service	1.3.1
Range方法	1.3.1.1
Put方法	1.3.1.2
DeleteRange方法	1.3.1.3
Txn方法	1.3.1.4
Compact方法	1.3.1.5
Watch service	1.3.2
Watch方法	1.3.2.1
Lease service	1.3.3
LeaseGrant方法	1.3.3.1
LeaseRevoke方法	1.3.3.2
LeaseKeepAlive方法	1.3.3.3
LeaseTimeToLive方法	1.3.3.4
并发 API 参考文档	1.4
Lock service	1.4.1
Lock方法	1.4.1.1
Unlock方法	1.4.1.2
Election service	1.4.2
Campaign方法	1.4.2.1
Proclaim方法	1.4.2.2
Leader方法	1.4.2.3
Observe方法	1.4.2.4
Resign方法	1.4.2.5
全文标签总览	1.5

Etcd官方文档中文版

Etcd官方文档中文版.

当前内容：

- [官方文档\(翻译\)](#)
- [API参考文档\(翻译\)](#)
- [并发API参考文档\(翻译\)](#)

官方文档

注：内容翻译自 <https://github.com/coreos/etcd/blob/master/Documentation>

etcd 是一个分布式键值对存储，设计用来可靠而快速的保存关键数据并提供访问。通过分布式锁，leader选举和写屏障(write barriers)来实现可靠的分布式协作。etcd集群是为高可用，持久性数据存储和检索而准备。

开始

现在 etcd 的用户和开发者可以从 [下载并构建](#) etcd开始。在获取etcd之后，参照 [quick demo](#) 来感受构建和操作etcd集群的基本方式。

使用 etcd 开发

开始使用 etcd 作为分布式键值存储的最简单的方式是 [搭建本地集群](#)

- [搭建本地集群](#)
- [和 etcd 交互](#)
- gRPC [etcd core](#) 和 [etcd concurrency API](#) 参考文档
- 经由 gRPC 网关的HTTP JSON API
- [gRPC 命名和发现](#)
- [客户端](#) 和 [代理](#) 命名空间
- [内嵌的etcd](#)
- [试验性的特性和 API](#)
- [系统限制](#)

操作 etcd 集群

管理员，需要为支持的开发人员创建可靠而可扩展的键值存储，应该从 [多机集群](#) 开始。

搭建 etcd

- [配置](#)
- [多成员集群](#)
- [在容器内运行etcd集群](#)
- [gRPC代理\(TBD\)](#)

- [L4 网关](#)

系统配置

- [支持平台](#)
- [硬件推荐\(TBD\)](#)
- [性能评测](#)
- [调优\(TBD\)](#)

平台指南

注：暂时未翻译这部分内容

- [Amazon Web Services](#)
- [Container Linux, systemd](#)
- [FreeBSD](#)
- [Docker container](#)
- [rkt container](#)

安全

— [TLS](#) — [基于角色的访问控制\(TBD\)](#)

维护和排错

- [常见问题\(TBD\)](#)
- [监控\(TBD\)](#)
- [维护](#)
- [故障模式](#)
- [灾难恢复](#)

升级和兼容

注：暂时未翻译这部分内容

- [版本](#)
- [Migrate applications from using API v2 to API v3](#)
- [Upgrading a v2.3 cluster to v3.0](#)
- [Upgrading a v3.0 cluster to v3.1](#)
- [Upgrading a v3.1 cluster to v3.2](#)

学习

要学习更多 `etcd` 背后的概念和内部细节，请阅读下面的内容:

- [为什么是etcd?](#)
- [理解数据模型](#)
- [理解API](#)
- [术语](#)
- [API保证](#)
- **Internals**
 - [认证子系统\(TBD\)](#)

开发指南

内容

etcd 开发指南的内容如下：

- [搭建本地集群](#)
- [和 etcd 交互](#)
- [API 参考文档](#)
- [API 并发参考文档](#)
- [gRPC 网关](#)
- [gRPC 命名和发现](#)
- [试验性的 API 和特性](#)
- [系统限制](#)

特别说明

1. 开发指南针对的是 etcd3 的使用者，如果只是 "用" etcd，可以重点阅读这部分内容。
2. 内容来自 <https://github.com/coreos/etcd/tree/master/Documentation/dev-guide>
3. 开发指南打包在 etcd3 的发行包中(`Documentent` 目录)，方便随时阅读。

搭建本地集群

对于测试和开发部署，最快最简单的方式是搭建本地集群。对于产品部署，参考 [集群](#) 章节。

本地独立集群

注：独立集群 指只有一台服务器的集群。

部署 etcd 集群作为独立集群是直截了当的。仅用一个命令就可以启动它：

```
$ ./etcd
...
```

启动的 etcd 成员在 `localhost:2379` 监听客户端请求。

通过使用 `etcdctl` 来和已经启动的集群交互：

```
# 使用 API 版本 3
$ export ETCDCCTL_API=3

$ ./etcdctl put foo bar
OK

$ ./etcdctl get foo
bar
```

本地多成员集群

注：多成员集群 指有多台服务器的集群。

提供 `Procfile` 用于简化搭建本地多成员集群。通过少量命令就可以启动多成员集群：

```
# 安装 goreman 程序来控制基于 Profile 的应用程序。
$ go get github.com/mattn/goreman
$ goreman -f Procfile start
...
```

注1：必须先安装 go，请见章节 [Go语言安装](#)

注2：这里所说的 `Procfile` 文件是来自 `etcd` 的 [github](#) 项目的根目录下的 `Procfile` 文件，但是需要修改一下，将里面的 `bin/etcd` 修改为 `etcd`

启动的成员各自在 `localhost:12379` , `localhost:22379` , 和 `localhost:32379` 上监听客户端请求。

注：英文原文中是 `localhost:12379` 用的是 12379 端口，但是实际上述 Procfile 文件中启动的是 2379 端口，如果连接时发现无法访问，请自行修改。下面的 12379 也是如此，请自行修改为 2379。

通过使用 `etcdctl` 来和已经启动的集群交互：

```
# 使用 API 版本 3
$ export ETCDCCTL_API=3

$ etcdctl --write-out=table --endpoints=localhost:12379 member list
+-----+-----+-----+-----+-----+
--+
|      ID      | STATUS | NAME  | PEER ADDRS | CLIENT ADDRS |
|              |        |       |             |               |
+-----+-----+-----+-----+-----+
--+
| 8211f1d0f64f3269 | started | infra1 | http://127.0.0.1:12380 | http://127.0.0.1:12379 |
| 91bc3c398fb3c146 | started | infra2 | http://127.0.0.1:22380 | http://127.0.0.1:22379 |
| fd422379fda50e48 | started | infra3 | http://127.0.0.1:32380 | http://127.0.0.1:32379 |
+-----+-----+-----+-----+-----+
--+

$ etcdctl --endpoints=localhost:12379 put foo bar
OK
```

为了体验 `etcd` 的容错性，杀掉一个成员：

```
# 杀掉 etcd2
$ goreman run stop etcd2
# 注：实测这个命令无法停止etcd，最后还是用ps命令找出pid，然后kill
# ps -ef | grep etcd | grep 127.0.0.1:22379
# kill ****

$ etcdctl --endpoints=localhost:12379 put key hello
OK

$ etcdctl --endpoints=localhost:12379 get key
hello

# 试图从被杀掉的成员获取key
$ etcdctl --endpoints=localhost:22379 get key
2016/04/18 23:07:35 grpc: Conn.resetTransport failed to create client transport: connection error: desc = "transport: dial tcp 127.0.0.1:22379: getsockopt: connection refused"; Reconnecting to "localhost:22379"
Error: grpc: timed out trying to connect

# 重启被杀掉的成员
# 注：实测这个restart命令可用
$ goreman run restart etcd2

# 从重启的成员获取key
$ etcdctl --endpoints=localhost:22379 get key
hello
```

了解更多和 etcd 的交互，请阅读 [和 etcd 交互](#)

和 etcd 交互

用户通常通过设置或者获取键的值来和 etcd 交互。这一节描述如何使用 etcdctl 来操作，etcdctl 是一个和 etcd 服务器交互的命令行工具。这里描述的概念也适用于 gRPC API 或者客户端类库 API。

默认，为了向后兼容 etcdctl 使用 v2 API 来和 etcd 服务器通讯。为了让 etcdctl 使用 v3 API 来和 etcd 通讯，API 版本必须通过环境变量 `ETCDCTL_API` 设置为版本3。

```
export ETCDCTL_API=3
```

查找版本

在查找适当命令以便对 etcd 执行各种操作时，etcdctl 版本和 Server API 版本很有用。

以下是查找版本的命令：

```
$ etcdctl version
etcdctl version: 3.1.0-alpha.0+git
API version: 3.1
```

写入键

应用通过写入键来储存键到 etcd 中。每个存储的键通过 Raft 协议复制到 etcd 集群的所有成员来实现一致性和可靠性。

这是设置键 `foo` 的值为 `bar` 的命令：

```
$ etcdctl put foo bar
OK
```

而且可以通过附加租约的方式为键设置特定时间间隔。

这是将键 `foo1` 的值设置为 `bar1` 并维持 10s 的命令：

```
$ etcdctl put foo1 bar1 --lease=1234abcd
OK
```

注意：上面命令中的租约id `1234abcd` 是创建租约时返回的，这个 id 随即被附加到键。

读取键

应用可以从 etcd 集群中读取键的值。查询可以读取单个 key，或者某个范围的键。

假设 etcd 集群存储有下面的键：

```
foo = bar
foo1 = bar1
foo2 = bar2
foo3 = bar3
```

这是读取键 `foo` 的值的命令：

```
$ etcdctl get foo
foo
bar
```

这是以16进制格式读取键的值的命令：

```
$ etcdctl get foo --hex
\x66\x6f\x6f      # 键
\x62\x61\x72      # 值
```

这是只读取键 `foo` 的值的命令：

```
$ etcdctl get foo --print-value-only
bar
```

这是范围覆盖从 `foo` to `foo3` 的键的命令：

```
$ etcdctl get foo foo3
foo
bar
foo1
bar1
foo2
bar2
```

注意 `foo3` 不在范围之内，因为范围是半开区间 `[foo, foo3)`，不包含 `foo3`。

这是范围覆盖以 `foo` 为前缀的所有键的命令：

```
$ etcdctl get --prefix foo
foo
bar
foo1
bar1
foo2
bar2
foo3
bar3
```

这是范围覆盖以 `foo` 为前缀的所有键的命令，结果数量限制为2：

```
$ etcdctl get --prefix --limit=2 foo
foo
bar
foo1
bar1
```

读取键过往版本的值

应用可能想读取键的被替代的值。例如，应用可能想通过访问键的过往版本来回滚到旧的配置。或者，应用可能想通过多个请求来得到一个覆盖多个键的统一视图，而这些请求可以通过访问键历史记录而来。因为 `etcd` 集群上键值存储的每个修改都会增加 `etcd` 集群的全局修订版本，应用可以通过提供旧有的 `etcd` 修改版本来读取被替代的键。

假设 `etcd` 集群已经有下列键：

```
foo = bar           # revision = 2
foo1 = bar1          # revision = 3
foo = bar_new        # revision = 4
foo1 = bar1_new       # revision = 5
```

这里是访问键的过往版本的例子：

```
$ etcdctl get --prefix foo # 访问键的最新版本
foo
bar_new
foo1
bar1_new

$ etcdctl get --prefix --rev=4 foo # 访问修订版本为 4 时的键的版本
foo
bar_new
foo1
bar1

$ etcdctl get --prefix --rev=3 foo # 访问修订版本为 3 时的键的版本
foo
bar
foo1
bar1

$ etcdctl get --prefix --rev=2 foo # 访问修订版本为 2 时的键的版本
foo
bar

$ etcdctl get --prefix --rev=1 foo # 访问修订版本为 1 时的键的版本
```

读取大于等于指定键的 **byte** 值的键

应用可能想读取大于等于指定键的 **byte** 值的键。

假设 **etcd** 集群已经有下列键：

```
a = 123
b = 456
z = 789
```

这是读取大于等于键 **b** 的 **byte** 值的键的命令：

```
$ etcdctl get --from-key b
b
456
z
789
```

删除键

应用可以从 **etcd** 集群中删除一个键或者特定范围的键。

假设 etcd 集群已经有下列键：

```
foo = bar
foo1 = bar1
foo3 = bar3
zoo = val
zoo1 = val1
zoo2 = val2
a = 123
b = 456
z = 789
```

这是删除键 `foo` 的命令：

```
$ etcdctl del foo
1 # 删除了一个键
```

这是删除从 `foo` to `foo9` 范围的键的命令：

```
$ etcdctl del foo foo9
2 # 删除了两个键
```

这是删除键 `zoo` 并返回被删除的键值对的命令：

```
$ etcdctl del --prev-kv zoo
1 # 一个键被删除
zoo # 被删除的键
val # 被删除的键的值
```

这是删除前缀为 `zoo` 的键的命令：

```
$ etcdctl del --prefix zoo
2 # 删除了两个键
```

这是删除大于等于键 `b` 的 `byte` 值的键的命令：

```
$ etcdctl del --from-key b
2 # 删除了两个键
```

观察键的变化

应用可以观察一个键或者范围内的键来监控任何更新。

这是在键 `foo` 上进行观察的命令：

```
$ etcdctl watch foo
# 在另外一个终端：etcdctl put foo bar
foo
bar
```

这是以16进制格式在键 `foo` 上进行观察的命令：

```
$ etcdctl watch foo --hex
# 在另外一个终端：etcdctl put foo bar
PUT
\x66\x6f\x6f      # 键
\x62\x61\x72      # 值
```

这是观察从 `foo` to `foo9` 范围内键的命令：

```
$ etcdctl watch foo foo9
# 在另外一个终端：etcdctl put foo bar
PUT
foo
bar
# 在另外一个终端：etcdctl put foo1 bar1
PUT
foo1
bar1
```

这是观察前缀为 `foo` 的键的命令：

```
$ etcdctl watch --prefix foo
# 在另外一个终端：etcdctl put foo bar
PUT
foo
bar
# 在另外一个终端：etcdctl put fooz1 barz1
PUT
fooz1
barz1
```

这是观察多个键 `foo` 和 `zoo` 的命令：

```
$ etcdctl watch -i
$ watch foo
$ watch zoo
# 在另外一个终端: etcdctl put foo bar
PUT
foo
bar
# 在另外一个终端: etcdctl put zoo val
PUT
zoo
val
```

观察 key 的历史改动

应用可能想观察 etcd 中键的历史改动。例如，应用想接收到某个键的所有修改。如果应用一直连接到 etcd，那么 `watch` 就足够好了。但是，如果应用或者 etcd 出错，改动可能发生在出错期间，这样应用就没法实时接收到这个更新。为了保证更新被交付，应用必须能够观察到键的历史变动。为了做到这点，应用可以在观察时指定一个历史修订版本，就像读取键的过往版本一样。

假设我们完成了下列操作序列：

```
$ etcdctl put foo bar          # revision = 2
OK
$ etcdctl put foo1 bar1       # revision = 3
OK
$ etcdctl put foo bar_new     # revision = 4
OK
$ etcdctl put foo1 bar1_new   # revision = 5
OK
```

这是观察历史改动的例子：

```
# 从修订版本 2 开始观察键 `foo` 的改动
$ etcdctl watch --rev=2 foo
PUT
foo
bar
PUT
foo
bar_new
```

```
# 从修订版本 3 开始观察键 `foo` 的改动
$ etcdctl watch --rev=3 foo
PUT
foo
bar_new
```

这是从上一次历史修改开始观察的例子(注：貌似原文有误，这里应该是观察变更时同时返回修改之前的值)：

```
# 在键 `foo` 上观察变更并返回被修改的值和上个修订版本的值
$ etcdctl watch --prev-kv foo
# 在另外一个终端：etcdctl put foo bar_latest
PUT
foo          # 键
bar_new      # 在修改前键foo的上一个值
foo          # 键
bar_latest   # 修改后键foo的值
```

压缩修订版本

如我们提到的，etcd 保存修订版本以便应用可以读取键的过往版本。但是，为了避免积累无限数量的历史数据，压缩过往的修订版本就变得很重要。压缩之后，etcd 删除历史修订版本，释放资源来提供未来使用。所有修订版本在压缩修订版本之前的被替代的数据将不可访问。

这是压缩修订版本的命令：

```
$ etcdctl compact 5
compactd revision 5

# 在压缩修订版本之前的任何修订版本都不可访问
$ etcdctl get --rev=4 foo
Error: rpc error: code = 11 desc = etcdserver: mvcc: required revision has been compacted
```

注意：etcd 服务器的当前修订版本可以在任何键(存在或者不存在)以json格式使用get命令来找到。下面展示的例子中 mykey 是在 etcd 服务器中不存在的：

```
$ etcdctl get mykey -w=json
{"header":{"cluster_id":14841639068965178418,"member_id":10276657743932975437,"revision":15,"raft_term":4}}
```

授予租约

应用可以为 etcd 集群里面的键授予租约。当键被附加到租约时，它的存活时间被绑定到租约的存活时间，而租约的存活时间相应的被 `time-to-live` (TTL) 管理。在租约授予时每个租约的最小 TTL 值由应用指定。租约的实际 TTL 值是不低于最小 TTL，由 etcd 集群选择。一旦租约的 TTL 到期，租约就过期并且所有附带的键都将被删除。

这是授予租约的命令：

```
# 授予租约，TTL为10秒
$ etcdctl lease grant 10
lease 32695410dcc0ca06 granted with TTL(10s)

# 附加键 foo 到租约32695410dcc0ca06
$ etcdctl put --lease=32695410dcc0ca06 foo bar
OK
```

撤销租约

应用通过租约 id 可以撤销租约。撤销租约将删除所有它附带的 key。

假设我们完成了下列的操作：

```
$ etcdctl lease grant 10
lease 32695410dcc0ca06 granted with TTL(10s)
$ etcdctl put --lease=32695410dcc0ca06 foo bar
OK
```

这是撤销同一个租约的命令：

```
$ etcdctl lease revoke 32695410dcc0ca06
lease 32695410dcc0ca06 revoked

$ etcdctl get foo
# 空应答，因为租约撤销导致foo被删除
```

维持租约

应用可以通过刷新键的 TTL 来维持租约，以便租约不过期。

假设我们完成了下列操作：

```
$ etcdctl lease grant 10
lease 32695410dcc0ca06 granted with TTL(10s)
```

这是维持同一个租约的命令：

```
$ etcdctl lease keep-alive 32695410dcc0ca06
lease 32695410dcc0ca06 keepalived with TTL(10)
lease 32695410dcc0ca06 keepalived with TTL(10)
lease 32695410dcc0ca06 keepalived with TTL(10)
...
```

获取租约信息

应用程序可能想知道租约信息，以便可以更新或检查租约是否仍然存在或已过期。应用程序也可能想知道有那些键附加到了特定租约。

假设我们完成了下列操作序列：

```
# 授予租约，TTL为500秒
$ etcdctl lease grant 500
lease 694d5765fc71500b granted with TTL(500s)

# 将键 zoo1 附加到租约 694d5765fc71500b
$ etcdctl put zoo1 val1 --lease=694d5765fc71500b
OK

# 将键 zoo2 附加到租约 694d5765fc71500b
$ etcdctl put zoo2 val2 --lease=694d5765fc71500b
OK
```

这是获取租约信息的命令：

```
$ etcdctl lease timetolive 694d5765fc71500b
lease 694d5765fc71500b granted with TTL(500s), remaining(258s)
```

这是获取租约信息和租约附带的键的命令：

```
$ etcdctl lease timetolive --keys 694d5765fc71500b
lease 694d5765fc71500b granted with TTL(500s), remaining(132s), attached keys([zoo2 zo
o1])

# 如果租约已经过期或者不存在，它将给出下面的应答：
Error: etcdserver: requested lease not found
```


核心 API 参考文档

官方文档中的 [API reference](#)，内容是从 .proto 文件生成的，service和方法定义/message定义一起构成一个庞大的单页HTML文件，不方便阅读和查阅。

因此在这次文档翻译中，将内容提取为单独的 [核心 API 参考文档](#)，同时为了方便阅读，我们遵循gitbook的习惯，按照服务/方法分开形成章节结构。

并发 **API** 参考文档

etcd 在 3.1 和 3.2 版本中，新增了并发 API，官方文档中提供了 的 [API Concurrent reference](#)。

我们以同样的方式，将这个参考文档的内容提取为单独的 [并发 API 参考文档](#)。

gRPC 网关

为什么用 `grpc-gateway`

`etcd v3` 使用 `gRPC` 作为它的消息协议。`etcd` 项目包括基于 `gRPC` 的 `Go client` 和 命令行工具 `etcdctl`，通过 `gRPC` 和 `etcd` 集群通讯。对于不支持 `gRPC` 支持的语言，`etcd` 提供 JSON 的 `grpc-gateway`。这个网关提供 RESTful 代理，翻译 HTTP/JSON 请求为 `gRPC` 消息。

使用 `grpc-gateway`

网关接受 `etcd` 的 `protocol buffer` 消息定义的 `JSON mapping`。注意 `key` 和 `value` 字段被定义为 `byte` 数组，因此必须在 JSON 中以 `base64` 编码。下面例子使用 `curl`，但是任何 HTTP/JSON 客户端都可以如此工作。

设置和获取键

使用 `v3alpha/kv/range` 和 `v3alpha/kv/put` 服务来读取和写入键:

```
# https://www.base64encode.org/
# foo is 'Zm9v' in Base64
# bar is 'YmFy'

curl -L http://localhost:2379/v3alpha/kv/put \
  -X POST -d '{"key": "Zm9v", "value": "YmFy"}'
# {"header":{"cluster_id":"12585971608760269493","member_id":"13847567121247652255","revision":"2","raft_term":"3"}}

curl -L http://localhost:2379/v3alpha/kv/range \
  -X POST -d '{"key": "Zm9v"}'
# {"header":{"cluster_id":"12585971608760269493","member_id":"13847567121247652255","revision":"2","raft_term":"3"},"kvs":[{"key":"Zm9v","create_revision":"2","mod_revision":"2","version":"1","value":"YmFy"}],"count":"1"}
```

观察键

使用 `v3alpha/watch` 服务来观察键:

```
curl http://localhost:2379/v3alpha/watch \  
    -X POST -d '{"create_request": {"key": "Zm9v"}}' &  
# {"result":{"header":{"cluster_id":"12585971608760269493","member_id":"13847567121247652255","revision":"1","raft_term":"2"},"created":true}}  
  
curl -L http://localhost:2379/v3alpha/kv/put \  
    -X POST -d '{"key": "Zm9v", "value": "YmFy"}' >/dev/null 2>&1  
# {"result":{"header":{"cluster_id":"12585971608760269493","member_id":"13847567121247652255","revision":"2","raft_term":"2"},"events":[{"kv":{"key":"Zm9v","create_revision":"2","mod_revision":"2","version":"1","value":"YmFy"}}]}}
```

事务

使用 `v3alpha/kv/txn` 发起事务:

```
curl -L http://localhost:2379/v3alpha/kv/txn \  
    -X POST \  
    -d '{"compare":[{"target":"CREATE","key":"Zm9v","createRevision":"2"}],"success":[{"requestPut":{"key":"Zm9v","value":"YmFy"}}]}'  
# {"header":{"cluster_id":"12585971608760269493","member_id":"13847567121247652255","revision":"3","raft_term":"2"},"succeeded":true,"responses":[{"response_put":{"header":{"revision":"3"}}}]}
```

认证

使用 `v3alpha/auth` 服务搭建认证:

```
# 创建 root 用户
curl -L http://localhost:2379/v3alpha/auth/user/add \
  -X POST -d '{"name": "root", "password": "pass"}'
# {"header":{"cluster_id":"14841639068965178418","member_id":"10276657743932975437","revision":"1","raft_term":"2"}}

# 创建 root 角色
curl -L http://localhost:2379/v3alpha/auth/role/add \
  -X POST -d '{"name": "root"}'
# {"header":{"cluster_id":"14841639068965178418","member_id":"10276657743932975437","revision":"1","raft_term":"2"}}

# 授予 root 角色
curl -L http://localhost:2379/v3alpha/auth/user/grant \
  -X POST -d '{"user": "root", "role": "root"}'
# {"header":{"cluster_id":"14841639068965178418","member_id":"10276657743932975437","revision":"1","raft_term":"2"}}

# 开启认证
curl -L http://localhost:2379/v3alpha/auth/enable -X POST -d '{}
# {"header":{"cluster_id":"14841639068965178418","member_id":"10276657743932975437","revision":"1","raft_term":"2"}}
```

使用 `v3alpha/auth/authenticate` 为认证 token 做认证:

```
# 为 root 用户 获取认证 token
curl -L http://localhost:2379/v3alpha/auth/authenticate \
  -X POST -d '{"name": "root", "password": "pass"}'
# {"header":{"cluster_id":"14841639068965178418","member_id":"10276657743932975437","revision":"1","raft_term":"2"},"token":"sssvIpwfnLAcWAQH.9"}
```

为认证 token 设置 `Authorization` header，以便在获取键时使用认证证书:

```
curl -L http://localhost:2379/v3alpha/kv/put \
  -H 'Authorization : sssvIpwfnLAcWAQH.9' \
  -X POST -d '{"key": "Zm9v", "value": "YmFy"}'
# {"header":{"cluster_id":"14841639068965178418","member_id":"10276657743932975437","revision":"2","raft_term":"2"}}
```

Swagger

生成的 [Swagger](#) API 定义可以在 [rpc.swagger.json](#) 找到.

gRPC 命名与发现

etcd 提供了一个 gRPC 解析器来支持替代名称系统，从 etcd 获取端点以发现 gRPC 服务。底层的机制是基于观察带有服务名称前缀的键的更新。

用 go-grpc 使用 etcd 发现

etcd 客户端提供了一个 gRPC 解析器，用于使用 etcd 后端解析 gRPC 端点。解析器使用 etcd 客户端初始化并给出解析解析的目标：

```
import (
    "github.com/coreos/etcd/clientv3"
    etcdnaming "github.com/coreos/etcd/clientv3/naming"

    "google.golang.org/grpc"
)

...

cli, cerr := clientv3.NewFromURL("http://localhost:2379")
r := &etcdnaming.GRPCResolver{Client: cli}
b := grpc.RoundRobin(r)
conn, gerr := grpc.Dial("my-service", grpc.WithBalancer(b))
```

管理服务端点

etcd 解析器将解析目标加"/"(如"my-service/")的前缀下，并带有 json 编码 go-grpc

`naming.Update` 值的所有键作为潜在的服务端点对待。通过创建新的键将端点添加到服务中，并通过删除键从服务中删除他们。

添加端点

新的端点可以通过 `etcdctl` 添加到服务中：

```
ETCDCTL_API=3 etcdctl put my-service/1.2.3.4 '{"Addr":"1.2.3.4","Metadata":"..."}'
```

etcd 客户端的 `GRPCResolver.Update` 方法可以同样用匹配 'Addr' 的键注册新的端点：

```
r.Update(context.TODO(), "my-service", naming.Update{Op: naming.Add, Addr: "1.2.3.4",  
Metadata: "..."}})
```

删除端点

通过 `etcdctl` 可以从服务中删除主机：

```
ETCDCTL_API=3 etcdctl del my-service/1.2.3.4
```

`etcd` 客户端的 `GRPCResolver.Update` 方法可以同样支持删除端点：

```
r.Update(context.TODO(), "my-service", naming.Update{Op: naming.Delete, Addr: "1.2.3.4"  
})
```

带租约注册端点

带租约注册端点确保如果主机不能维持 `keepalive` 心跳（例如，它的机器宕机了），它将从服务中删除：

```
lease=`ETCDCTL_API=3 etcdctl lease grant 5 | cut -f2 -d' '`  
ETCDCTL_API=3 etcdctl put --lease=$lease my-service/1.2.3.4 '{"Addr":"1.2.3.4","Metada  
ta":"..."}'  
ETCDCTL_API=3 etcdctl lease keep-alive $lease
```

试验性的 **API** 和特性

etcd 项目的大部分是稳定的，但是我们依然在快速前行！我们信仰快速发布的哲学。我们想得到还在开发和完善中的特性的早期反馈。因此，有，而且将会有更多，试验性的特性和 API。我们计划基于社区的早期反馈来在后面几个发布中改进这些特性，或者如果没有人有趣就中止他们。不要在产品环境中依赖任何试验性的特性或者 API。

当前试验性的 **API**/特性是：

(暂无)

系统限制

请求大小限制

`etcd` 被设计用于处理小型的键值对，典型如元数据。更大的请求可以工作，但可能会增加其他请求的延迟。目前，`etcd` 保证支持不超过 1MB 数据的 RPC 请求。将来，大小限制可能会松动或可配置。

储存大小限制

默认存储大小限制是 2GB, 可以通过 `--quota-backend-bytes` 标记配置; 最大支持 8GB.

操作 etcd 集群

内容

- 搭建etcd集群
- 搭建etcd网关
- 在容器内运行etcd集群
- 配置
- 加密(TODO)
- Monitoring
- 维护
- 理解失败
- 灾难恢复
- 性能
- 版本
- 支持平台

额外说明

1. 这些内容相当于是 etcd3 的管理手册，针对的是 etcd3 的管理者(如运维人员)。对于运维人员，需要重点阅读这些内容。
2. 内容来自 github 官网，地址：
<https://github.com/coreos/etcd/tree/master/Documentation/op-guide>
3. 这些文档打包在 etcd3 的发行包中(Documentent / op-guide 目录)，平时使用时可以随时阅读。

集群指南

概述

启动 etcd 集群要求每个成员知道集群中的其他成员。在一些场景中，集群成员的 IP 地址可能无法提前知道。在这种情况下，etcd 集群可以在发现服务的帮助下启动。

一旦 etcd 集群启动并运行，可以通过 [运行时重配置](#) 来添加或者移除成员。为了更好的理解运行时重配置背后的设计，建议阅读 [运行时重配置的设计](#)。

这份指南将覆盖下列用于启动 etcd 集群的机制：

- [静态](#)
- [etcd 发现](#)
- [DNS 发现](#)

启动机制的每一种都将用于启动三台机器的 etcd 集群，详情如下：

名字	地址	主机
infra0	10.0.1.10	infra0.example.com
infra1	10.0.1.11	infra1.example.com
infra2	10.0.1.12	infra2.example.com

静态

如果在启动前我们知道集群成员，他们的地址和集群的大小，我们可以使用通过设置 `initial-cluster` 标记来离线启动配置。每个机器将得到下列环境变量或者命令行：

```
ETCD_INITIAL_CLUSTER="infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=http://10.0.1.12:2380"
ETCD_INITIAL_CLUSTER_STATE=new
```

```
--initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=http://10.0.1.12:2380 \
--initial-cluster-state new
```

注意：在 `initial-cluster` 中指定的 URL 是 *advertised peer URLs*，例如，他们将匹配对应节点的 `initial-advertise-peer-urls` 的值。

如果使用同样的配置启动多个集群(或者创建并部署单个集群)用于测试目的,强烈推荐每个集群给予一个唯一的 `initial-cluster-token`。这样做之后,etcd 可以为集群生成唯一的集群 ID 和成员 ID,甚至他们有完全一样的配置。这可以将 etcd 从可能让集群孵化的跨集群交互中保护起来。

etcd 在 `listen-client-urls` 上接收客户端访问。etcd 成员将 `advertise-client-urls` 指定的 URI 上通告给其他成员,代理和客户端。常见的错误是设置 `advertise-client-urls` 为 `localhost` 或者留空为默认值,如果远程客户端可以达到 etcd。

在每台机器上,使用这些标记启动 etcd:

```
$ etcd --name infra0 --initial-advertise-peer-urls http://10.0.1.10:2380 \
--listen-peer-urls http://10.0.1.10:2380 \
--listen-client-urls http://10.0.1.10:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.10:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=
http://10.0.1.12:2380 \
--initial-cluster-state new
```

```
$ etcd --name infra1 --initial-advertise-peer-urls http://10.0.1.11:2380 \
--listen-peer-urls http://10.0.1.11:2380 \
--listen-client-urls http://10.0.1.11:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.11:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=
http://10.0.1.12:2380 \
--initial-cluster-state new
```

```
$ etcd --name infra2 --initial-advertise-peer-urls http://10.0.1.12:2380 \
--listen-peer-urls http://10.0.1.12:2380 \
--listen-client-urls http://10.0.1.12:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.12:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=
http://10.0.1.12:2380 \
--initial-cluster-state new
```

以 `--initial-cluster` 开头的命令行参数将在 etcd 随后的运行中被忽略。可以在初始化启动进程之后随意的删除环境变量或者命令行标记。如果配置需要稍后修改(例如,添加成员到集群或者从集群中移除成员),查看 [运行时配置](#) 指南。

TLS

etcd 支持通过 TLS 协议的加密通讯。TLS 通道可以用于加密伙伴间的内部集群通讯，也可以用于加密客户端请求。这个章节提供例子来搭建使用伙伴和客户端 TLS 的集群。详细描述 etcd 的 TLS 支持的额外信息可以在 [加密指南](#)

自签名证书

使用自签名证书证书(self-signed certificates)的集群同时加密请求并认证它的连接。要启动使用自签名证书的集群，每个集群成员应该有一个唯一的通过共享的集群CA证书来签名的键对(key pair) (member.crt , member.key)，用于伙伴连接和客户端连接。证书可以通过仿照 etcd 搭建TLS 的例子来生成。

在每台机器上，etcd可以使用这些标记来启动：

```
$ etcd --name infra0 --initial-advertise-peer-urls http://10.0.1.10:2380 \
--listen-peer-urls https://10.0.1.10:2380 \
--listen-client-urls https://10.0.1.10:2379,https://127.0.0.1:2379 \
--advertise-client-urls https://10.0.1.10:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=https://10.0.1.10:2380,infra1=https://10.0.1.11:2380,infra2=https://10.0.1.12:2380 \
--initial-cluster-state new \
--client-cert-auth --trusted-ca-file=/path/to/ca-client.crt \
--cert-file=/path/to/infra0-client.crt --key-file=/path/to/infra0-client.key \
--peer-client-cert-auth --peer-trusted-ca-file=ca-peer.crt \
--peer-cert-file=/path/to/infra0-peer.crt --peer-key-file=/path/to/infra0-peer.key
```

```
$ etcd --name infra1 --initial-advertise-peer-urls https://10.0.1.11:2380 \
--listen-peer-urls https://10.0.1.11:2380 \
--listen-client-urls https://10.0.1.11:2379,https://127.0.0.1:2379 \
--advertise-client-urls https://10.0.1.11:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=https://10.0.1.10:2380,infra1=https://10.0.1.11:2380,infra2=https://10.0.1.12:2380 \
--initial-cluster-state new \
--client-cert-auth --trusted-ca-file=/path/to/ca-client.crt \
--cert-file=/path/to/infra1-client.crt --key-file=/path/to/infra1-client.key \
--peer-client-cert-auth --peer-trusted-ca-file=ca-peer.crt \
--peer-cert-file=/path/to/infra1-peer.crt --peer-key-file=/path/to/infra1-peer.key
```

```
$ etcd --name infra2 --initial-advertise-peer-urls https://10.0.1.12:2380 \
--listen-peer-urls https://10.0.1.12:2380 \
--listen-client-urls https://10.0.1.12:2379,https://127.0.0.1:2379 \
--advertise-client-urls https://10.0.1.12:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=https://10.0.1.10:2380,infra1=https://10.0.1.11:2380,infra2=
=https://10.0.1.12:2380 \
--initial-cluster-state new \
--client-cert-auth --trusted-ca-file=/path/to/ca-client.crt \
--cert-file=/path/to/infra2-client.crt --key-file=/path/to/infra2-client.key \
--peer-client-cert-auth --peer-trusted-ca-file=ca-peer.crt \
--peer-cert-file=/path/to/infra2-peer.crt --peer-key-file=/path/to/infra2-peer.key
```

自动证书

如果集群需要加密通讯，但是不需要认证连接，**etcd** 可以配置为自动生成 **key**。在初始化时，每个集群基于它的通告IP(advertised IP) 地址和主机名创建它自己的 **key** 集合。

在每台机器上，**etcd** 使用这些标记启动：

```
$ etcd --name infra0 --initial-advertise-peer-urls https://10.0.1.10:2380 \
--listen-peer-urls https://10.0.1.10:2380 \
--listen-client-urls https://10.0.1.10:2379,https://127.0.0.1:2379 \
--advertise-client-urls https://10.0.1.10:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=https://10.0.1.10:2380,infra1=https://10.0.1.11:2380,infra2=
=https://10.0.1.12:2380 \
--initial-cluster-state new \
--auto-tls \
--peer-auto-tls
```

```
$ etcd --name infra1 --initial-advertise-peer-urls https://10.0.1.11:2380 \
--listen-peer-urls https://10.0.1.11:2380 \
--listen-client-urls https://10.0.1.11:2379,https://127.0.0.1:2379 \
--advertise-client-urls https://10.0.1.11:2379 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster infra0=https://10.0.1.10:2380,infra1=https://10.0.1.11:2380,infra2=
=https://10.0.1.12:2380 \
--initial-cluster-state new \
--auto-tls \
--peer-auto-tls
```

```
$ etcd --name infra2 --initial-advertise-peer-urls https://10.0.1.12:2380 \  
--listen-peer-urls https://10.0.1.12:2380 \  
--listen-client-urls https://10.0.1.12:2379,https://127.0.0.1:2379 \  
--advertise-client-urls https://10.0.1.12:2379 \  
--initial-cluster-token etcd-cluster-1 \  
--initial-cluster infra0=https://10.0.1.10:2380,infra1=https://10.0.1.11:2380,infra2=  
=https://10.0.1.12:2380 \  
--initial-cluster-state new \  
--auto-tls \  
--peer-auto-tls
```

错误案例

案例1

在下面的例子中，我们没有在列举的节点列表中包含我们新的主机地址。如果这是一个新的集群，节点 必须 添加到初始化集群成员的列表中。

```
$ etcd --name infra1 --initial-advertise-peer-urls http://10.0.1.11:2380 \  
--listen-peer-urls https://10.0.1.11:2380 \  
--listen-client-urls http://10.0.1.11:2379,http://127.0.0.1:2379 \  
--advertise-client-urls http://10.0.1.11:2379 \  
--initial-cluster infra0=http://10.0.1.10:2380 \  
--initial-cluster-state new  
etcd: infra1 not listed in the initial cluster config  
exit 1
```

案例2

在这个例子中，我们试图映射节点(infra0)在不同地址(127.0.0.1:2380)而不是它在集群列表(10.0.1.10:2380)中列举的地址。如果这个节点是监听多个地址，所有地址 必须 在 "initial-cluster" 配置指令中反映出来。

```
$ etcd --name infra0 --initial-advertise-peer-urls http://127.0.0.1:2380 \  
--listen-peer-urls http://10.0.1.10:2380 \  
--listen-client-urls http://10.0.1.10:2379,http://127.0.0.1:2379 \  
--advertise-client-urls http://10.0.1.10:2379 \  
--initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=h  
ttp://10.0.1.12:2380 \  
--initial-cluster-state=new  
etcd: error setting up initial cluster: infra0 has different advertised URLs in the cl  
uster and advertised peer URLs list  
exit 1
```

案例3

如果伙伴被用配置参数的不同集合配置并试图加入这个集群，etcd 将报告集群 ID 不匹配并退出。

```
$ etcd --name infra3 --initial-advertise-peer-urls http://10.0.1.13:2380 \
--listen-peer-urls http://10.0.1.13:2380 \
--listen-client-urls http://10.0.1.13:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.13:2379 \
--initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra3=ht
tp://10.0.1.13:2380 \
--initial-cluster-state=new
etcd: conflicting cluster ID to the target cluster (c6ab534d07e8fcc4 != bc25ea2a74fb18
b0). Exiting.
exit 1
```

发现

在一些案例中，集群伙伴的 IP 可能无法提前知道。当使用云提供商或者网络使用 DHCP 时比较常见。在这些情况下，相比指定静态配置，可以使用已经存在的 etcd 集群来启动一个新的。我们称这个过程为“发现”。

有两个方法可以用来做发现：

- etcd 发现服务
- DNS SRV 记录

etcd 发现

为了更好的理解发现服务协议的设计，建议阅读发现服务项目 [文档](#)。

discovery URL 的存活时间

discovery URL 标识唯一的 etcd 集群。对于新的集群，总是创建 discovery URL 而不是重用 discovery URL。

此外，discovery URL 应该仅仅用于集群的初始化启动。在集群已经运行之后修改集群成员，阅读 [运行时重配置](#) 指南。

定制 etcd 发现服务

发现使用已有集群来启动自身。如果使用私有的 etcd 集群，可以创建像这样的 URL：

```
$ curl -X PUT https://myetcd.local/v2/keys/discovery/6c007a14875d53d9bf0ef5a6fc0257c817f0fb83/_config/size -d value=3
```

通过设置 URL 的 `size`，创建了带有期待集群大小为3的 `discovery` URL。

用于这个场景的 URL 将是

`https://myetcd.local/v2/keys/discovery/6c007a14875d53d9bf0ef5a6fc0257c817f0fb83` 而 `etcd` 成员将使用

`https://myetcd.local/v2/keys/discovery/6c007a14875d53d9bf0ef5a6fc0257c817f0fb83` 目录来注册，当他们启动时。

每个成员必须有指定不同的名字标记。`Hostname` 或者 `machine-id` 是个好选择。否则发现会因为重复名字而失败

现在我们用这些用于每个成员的相关标记启动 `etcd`：

```
$ etcd --name infra0 --initial-advertise-peer-urls http://10.0.1.10:2380 \
--listen-peer-urls http://10.0.1.10:2380 \
--listen-client-urls http://10.0.1.10:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.10:2379 \
--discovery https://myetcd.local/v2/keys/discovery/6c007a14875d53d9bf0ef5a6fc0257c817f0fb83
```

```
$ etcd --name infra1 --initial-advertise-peer-urls http://10.0.1.11:2380 \
--listen-peer-urls http://10.0.1.11:2380 \
--listen-client-urls http://10.0.1.11:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.11:2379 \
--discovery https://myetcd.local/v2/keys/discovery/6c007a14875d53d9bf0ef5a6fc0257c817f0fb83
```

```
$ etcd --name infra2 --initial-advertise-peer-urls http://10.0.1.12:2380 \
--listen-peer-urls http://10.0.1.12:2380 \
--listen-client-urls http://10.0.1.12:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.12:2379 \
--discovery https://myetcd.local/v2/keys/discovery/6c007a14875d53d9bf0ef5a6fc0257c817f0fb83
```

这将导致每个成员使用定制的 `etcd` 发现服务注册自身并开始集群，一旦所有的机器都已经注册。

公共 `etcd` 发现服务

如果没有现成的集群可用，可以使用托管在 `discovery.etcd.io` 的公共发现服务。为了使用 "new" endpoint 来创建私有发现 URL，使用命令：

```
$ curl https://discovery.etcd.io/new?size=3
https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
```

这将创建带有初始化预期大小为3个成员的集群。如果没有指定大小，将使用默认值3。

```
ETCD_DISCOVERY=https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
```

```
--discovery https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
```

每个成员必须有指定不同的名字标记。`Hostname` 或者 `machine-id` 是个好选择。否则发现会因为重复名字而失败

现在我们用这些用于每个成员的相关标记启动 `etcd`：

```
$ etcd --name infra0 --initial-advertise-peer-urls http://10.0.1.10:2380 \
--listen-peer-urls http://10.0.1.10:2380 \
--listen-client-urls http://10.0.1.10:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.10:2379 \
--discovery https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
```

```
$ etcd --name infra1 --initial-advertise-peer-urls http://10.0.1.11:2380 \
--listen-peer-urls http://10.0.1.11:2380 \
--listen-client-urls http://10.0.1.11:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.11:2379 \
--discovery https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
```

```
$ etcd --name infra2 --initial-advertise-peer-urls http://10.0.1.12:2380 \
--listen-peer-urls http://10.0.1.12:2380 \
--listen-client-urls http://10.0.1.12:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.12:2379 \
--discovery https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
```

这将导致每个成员使用定制的 `etcd` 发现服务注册自身并开始集群，一旦所有的机器都已经注册。

使用环境变量 `ETCD_DISCOVERY_PROXY` 来让 `etcd` 使用 HTTP 代理来连接到发现服务。

错误和警告案例

发现服务错误


```
$ etcd --name infra0 --initial-advertise-peer-urls http://10.0.1.10:2380 \
--listen-peer-urls http://10.0.1.10:2380 \
--listen-client-urls http://10.0.1.10:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.10:2379 \
--discovery https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
etcd: error: the cluster doesn't have a size configuration value in https://discovery.
etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de/_config
exit 1
```

警告

这是一个无害的警告，表明发现 URL 将在这台机器上被忽略。

```
$ etcd --name infra0 --initial-advertise-peer-urls http://10.0.1.10:2380 \
--listen-peer-urls http://10.0.1.10:2380 \
--listen-client-urls http://10.0.1.10:2379,http://127.0.0.1:2379 \
--advertise-client-urls http://10.0.1.10:2379 \
--discovery https://discovery.etcd.io/3e86b59982e49066c5d813af1c2e2579cbf573de
etcdserver: discovery token ignored since a cluster has already been initialized. Valid log found at /var/lib/etcd
```

DNS发现

DNS [SRV records](#) 可以作为发现机制使用。

`-discovery-srv` 标记可以用于设置 DNS domain name，在这里可以找到发现 SRV 记录。

下列 DNS SRV 记录将以列出的顺序查找：

- `_etcd-server-ssl._tcp.example.com`
- `_etcd-server._tcp.example.com`

如果 `_etcd-server-ssl._tcp.example.com` 被发现则 `etcd` 将在 TLS 上启动尝试启动进程。

为了帮助客户端发现 `etcd` 集群，下列 DNS SRV 记录将以列出的顺序查找：

- `_etcd-client._tcp.example.com`
- `_etcd-client-ssl._tcp.example.com`

如果发现 `_etcd-client-ssl._tcp.example.com`，客户端将在 SSL/TLS 上尝试和 `etcd` 集群通讯。

如果 `etcd` 不带定义的证书 authority 使用 TLS，发现域名(如, `example.com`) 必须匹配 SRV record domain (例如, `infra1.example.com`)。这是为了减轻仿制 SRV 记录来指向不同域名的损害；域名可能有 PKI 之下的有效证书，但是被未知的第三方控制。

创建 DNS SRV 记录

```
$ dig +noall +answer SRV _etcd-server._tcp.example.com
_etcd-server._tcp.example.com. 300 IN SRV 0 0 2380 infra0.example.com.
_etcd-server._tcp.example.com. 300 IN SRV 0 0 2380 infra1.example.com.
_etcd-server._tcp.example.com. 300 IN SRV 0 0 2380 infra2.example.com.
```

```
$ dig +noall +answer SRV _etcd-client._tcp.example.com
_etcd-client._tcp.example.com. 300 IN SRV 0 0 2379 infra0.example.com.
_etcd-client._tcp.example.com. 300 IN SRV 0 0 2379 infra1.example.com.
_etcd-client._tcp.example.com. 300 IN SRV 0 0 2379 infra2.example.com.
```

```
$ dig +noall +answer infra0.example.com infra1.example.com infra2.example.com
infra0.example.com. 300 IN A 10.0.1.10
infra1.example.com. 300 IN A 10.0.1.11
infra2.example.com. 300 IN A 10.0.1.12
```

使用 DNS 启动 etcd 集群

etcd 集群成员可以监听域名或者IP地址，启动进程将解析 DNS A 记录。

在 `--initial-advertise-peer-urls` 中解析出来的地址 必须匹配 在 SRV 目录中解析出来的地址中的一个。etcd 成员读取被解析的地址来发现它是否属于 SRV 记录定义的集群。

```
$ etcd --name infra0 \
--discovery-srv example.com \
--initial-advertise-peer-urls http://infra0.example.com:2380 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster-state new \
--advertise-client-urls http://infra0.example.com:2379 \
--listen-client-urls http://infra0.example.com:2379 \
--listen-peer-urls http://infra0.example.com:2380
```

```
$ etcd --name infra1 \
--discovery-srv example.com \
--initial-advertise-peer-urls http://infra1.example.com:2380 \
--initial-cluster-token etcd-cluster-1 \
--initial-cluster-state new \
--advertise-client-urls http://infra1.example.com:2379 \
--listen-client-urls http://infra1.example.com:2379 \
--listen-peer-urls http://infra1.example.com:2380
```

```
$ etcd --name infra2 \  
--discovery-srv example.com \  
--initial-advertise-peer-urls http://infra2.example.com:2380 \  
--initial-cluster-token etcd-cluster-1 \  
--initial-cluster-state new \  
--advertise-client-urls http://infra2.example.com:2379 \  
--listen-client-urls http://infra2.example.com:2379 \  
--listen-peer-urls http://infra2.example.com:2380
```

集群也可以使用 IP 地址而不是域名来启动：

```
$ etcd --name infra0 \  
--discovery-srv example.com \  
--initial-advertise-peer-urls http://10.0.1.10:2380 \  
--initial-cluster-token etcd-cluster-1 \  
--initial-cluster-state new \  
--advertise-client-urls http://10.0.1.10:2379 \  
--listen-client-urls http://10.0.1.10:2379 \  
--listen-peer-urls http://10.0.1.10:2380
```

```
$ etcd --name infra1 \  
--discovery-srv example.com \  
--initial-advertise-peer-urls http://10.0.1.11:2380 \  
--initial-cluster-token etcd-cluster-1 \  
--initial-cluster-state new \  
--advertise-client-urls http://10.0.1.11:2379 \  
--listen-client-urls http://10.0.1.11:2379 \  
--listen-peer-urls http://10.0.1.11:2380
```

```
$ etcd --name infra2 \  
--discovery-srv example.com \  
--initial-advertise-peer-urls http://10.0.1.12:2380 \  
--initial-cluster-token etcd-cluster-1 \  
--initial-cluster-state new \  
--advertise-client-urls http://10.0.1.12:2379 \  
--listen-client-urls http://10.0.1.12:2379 \  
--listen-peer-urls http://10.0.1.12:2380
```

网关

etcd 网关是一个简单的 TCP 代理，转发网络数据到 etcd 集群。请阅读 [网关指南](#) 来获取更多信息。

代理

当 `--proxy` 标记被设置时，etcd 运行于 [代理模式](#)。这个代理模式仅仅支持 etcd v2 API; 没有支持 v3 API 的计划。取而代之的是，对于 v3 API 支持，在 etcd 3.0 发布之后将会有一个新的有增强特性的代理。

为了搭建带有v2 API的代理的 etcd 集群，请阅读 [clustering doc in etcd 2.3 release](#).

运行时重配置

etcd 自带对渐进的运行时重配置的支持，这容许用户在运行时更新集群成员。

重配置请求仅能在集群成员的大多数正常工作时可以处理。强烈推荐 在产品中集群大小总是大于2.从一个两成员集群中移除一个成员是不安全的。在移除过程中如果有失败，集群可能无法前进而需要[从重大失败中重启](#)。

为了更好的理解运行时重配置后面的设计，建议阅读 [运行时重配置文档](#)。

重配置使用案例

让我们过一下一些重配置集群的常见理由。他们中的大多数仅仅涉及添加或者移除成员的组合，这些在后面的 [集群重配置操作](#) 下解释。

循环或升级多台机器

如果多个集群成员因为计划的维护(硬件升级，网络停工)而需要移动，推荐一次一个的修改多个成员。

移除 leader 是安全的，但是在选举过程发生的期间有短暂的停机时间。如果集群保存超过 50MB，推荐 [迁移成员的数据目录](#)。

修改集群大小

增加集群大小可以改善 [失败容忍度](#) 并提供更好的读取性能。因为客户端可以从任意成员读取，增加成员的数量可以提高整体的读取吞吐量。

减少集群大小可以改善集群的写入性能，作为交换是降低弹性。写入到集群是要复制到集群成员的大多数才能被认定已经提交。减少集群大小消减了大多数的数量，从而每次写入可以更快提交。

替换失败的机器

如果机器因为硬件故障，数据目录损坏，或者一些其他致命情况而失败，它应该尽快被替代。已经失败但是还没有移除的机器对法定人数有不利影响并减低对额外失败的容忍性。

为了替换机器，遵循从集群中 [移除成员](#) 的建议, 然后再 [添加新成员](#) 替代它的未知。如果集群保存超过50MB, 推荐 [迁移失败成员的数据目录](#)，如果它还可以访问。

从多数失败中重启集群

如果集群的多数已经丢失或者所有的节点已经修改了IP地址，则需要手工动作来安全恢复。

恢复过程中的基本步骤包括 [使用旧有数据创建新的集群](#)，强制单个成员成，并最终使用运行时配置来一次一个 [添加新的成员](#) 到这个新的集群。

集群重配置操作

现在我们心里有使用案例了，让我们展示每个案例中涉及到的操作。

在任何变动前，etcd 成员的简单多数(quorum) 必须可用。

对于任何其他到 etcd 的写入，这也是根本性的同样要求。

所有集群的改动一次一个的完成：

- 要更新单个成员peerURLs，做一个更新操作
- 要替代单个成员，做一个添加然后一个删除操作
- 要将成员从3增加到5,做两次添加操作
- 要将成员从5减少到3,做两次删除操作

所有这些案例将使用etcd自带的 `etcdctl` 命令行工具。

如果不用 `etcdctl` 修改成员，可以使用 [v2 HTTP members API](#) 或者 [v3 gRPC members API](#)。

更新成员

更新 advertise client URLs

为了更新成员的 advertise client URLs，简单用更新后的 client URL 标记(`--advertise-client-urls`)或者环境变量来重启这个成员(`ETCD_ADVERTISE_CLIENT_URLS`)。重新后的成员将自行发布更新后的URL。错误更新的client URL 将不会影响 etcd 集群的健康。

更新 advertise peer URLs

要更新成员的 advertise peer URLs, 首先通过成员命令更新它然后再重启成员。需要额外的行为是因为更新 peer URL 修改了集群范围配置并能影响 etcd 集群的健康。

要更新 peer URL，首先，我们需要找到目标成员的ID。使用 `etcdctl` 列出所有成员：

```
$ etcdctl member list
6e3bd23ae5f1eae0: name=node2 peerURLs=http://localhost:23802 clientURLs=http://127.0.0.1:23792
924e2e83e93f2560: name=node3 peerURLs=http://localhost:23803 clientURLs=http://127.0.0.1:23793
a8266ecf031671f3: name=node1 peerURLs=http://localhost:23801 clientURLs=http://127.0.0.1:23791
```

在这个例子中，让我们 `更新` `a8266ecf031671f3` 成员ID并修改它的 `peerURLs` 值为 `http://10.0.1.10:2380`。

```
$ etcdctl member update a8266ecf031671f3 http://10.0.1.10:2380
Updated member with ID a8266ecf031671f3 in cluster
```

删除成员

假设我们要删除的成员ID是 `a8266ecf031671f3`。

我们随后用 `remove` 命令来执行删除：

```
$ etcdctl member remove a8266ecf031671f3
Removed member a8266ecf031671f3 from cluster
```

此时目标成员将停止自身并在日志中打印出移除信息：

```
etcd: this member has been permanently removed from the cluster. Exiting.
```

可以安全的移除 `leader`，当然在新 `leader` 被选举时集群将不活动(`inactive`)。这个持续时间通常是选举超时时间加投票过程。

添加新成员

添加成员的过程有两个步骤：

- 通过 [HTTP members API](#) 添加新成员到集群, [gRPC members API](#), 或者 `etcdctl member add` 命令。
- 使用新的层原配置启动新成员，包括更新后的成员列表(以后成员加新成员)

使用 `etcdctl` 指定 `name` 和 `advertised peer URLs` 来添加新的成员到集群：

```
$ etcdctl member add infra3 http://10.0.1.13:2380
added member 9bf1b35fc7761a23 to cluster

ETCD_NAME="infra3"
ETCD_INITIAL_CLUSTER="infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=
http://10.0.1.12:2380,infra3=http://10.0.1.13:2380"
ETCD_INITIAL_CLUSTER_STATE=existing
```

etcdctl 已经给出关于新成员的集群信息并打印出成功启动它需要的环境变量。现在用关联的标记为新的成员启动新 etcd 进程：

```
$ export ETCD_NAME="infra3"
$ export ETCD_INITIAL_CLUSTER="infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:23
80,infra2=http://10.0.1.12:2380,infra3=http://10.0.1.13:2380"
$ export ETCD_INITIAL_CLUSTER_STATE=existing
$ etcd --listen-client-urls http://10.0.1.13:2379 --advertise-client-urls http://10.0.
1.13:2379 --listen-peer-urls http://10.0.1.13:2380 --initial-advertise-peer-urls http:
//10.0.1.13:2380 --data-dir %data_dir%
```

新成员将作为集群的一部分运行并立即开始赶上集群的其他成员。

如果添加多个成员，最佳实践是一次配置单个成员并在添加更多新成员前验证它正确启动。

如果添加新成员到一个节点的集群，在新成员启动前集群无法继续工作，因为它需要两个成员作为 **galosh** 才能在一致性上达成一致。这个行为仅仅发生在 `etcdctl member add` 影响集群和新成员成功建立连接到已有成员的时间内。

添加成员时的错误案例

在下面的案例中，我们没有在列举节点的列表中包含新的 **host**。如果这是一个新的集群，节点必须添加到初始化集群成员列表中。

```
$ etcd --name infra3 \
  --initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=h
ttp://10.0.1.12:2380 \
  --initial-cluster-state existing
etcdserver: assign ids error: the member count is unequal
exit 1
```

在这个案例中，我们给出一个和我们用来加入集群的(10.0.1.13:2380)不同的地址(10.0.1.14:2380)


```
$ etcd --name infra4 \  
  --initial-cluster infra0=http://10.0.1.10:2380,infra1=http://10.0.1.11:2380,infra2=h  
ttp://10.0.1.12:2380,infra4=http://10.0.1.14:2380 \  
  --initial-cluster-state existing  
etcdserver: assign ids error: unmatched member while checking PeerURLs  
exit 1
```

当我们使用一个被移除成员的数据目录来启动 etcd 时，etcd 将立即退出，如果它连接到任何集群中的活动成员：

```
$ etcd  
etcd: this member has been permanently removed from the cluster. Exiting.  
exit 1
```

严格重配置检查模式 (**-strict-reconfig-check**)

如上所述，添加新成员的最佳实践是一次配置单个成员并在添加更多新成员前验证它正确启动。这个逐步的方式非常重要，因为如果最新添加的成员没有正确配置(例如 peer URL 不正确)，集群会丢失法定人数。发生法定人数丢失是因为最新加入的成员被法定人数计数，即使这个成员对其他已经存在的成员是无法访问的。同样法定人数丢失可能发生在有连接问题或者操作问题时。

为了避免这个问题，etcd 提供选项 `-strict-reconfig-check`。如果这个选项被传递给 etcd，etcd 拒绝重配置请求，如果启动的成员的数量将少于被重配置的集群的法定人数。

推荐开启这个选项。当然，为了保持兼容它被默认关闭。

运行时重配置的设计

在分布式系统中，运行时重配置是最困难和最有错误倾向的特性，尤其是基于一致性的系统如 etcd。

继续阅读来学习关于 etcd 的运行时重配置命令的设计和我们如何解决这些问题。

两阶段配置修改保持集群安全

在 etcd 中，为了安全每个运行时重配置必须通过 [两阶段](#)。例如，为了添加成员，首先通知集群新配置然后再启动新成员。

阶段 1 - 通知集群新配置

为了添加成员到 etcd 集群，发起一个 API 调用来请求要添加一个新成员到集群。这是添加新成员到现有集群的唯一方法。当集群同意配置修改时 API 调用返回。

阶段 2 - 启动新成员

为了将 etcd 成员加入已有的集群，指定正确的 `initial-cluster` 并设置 `initial-cluster-state` 为 `existing`。当成员启动时，它会首先联系已有的集群并验证当前集群配置匹配在 `initial-cluster` 中期待的配置。当新成员成功启动时，集群就达到了期待的配置。

通过将过程拆分为两个分离的阶段，用户被强制去明确关于集群成员的修改。这实际给了用户更多灵活性并让事情容易推导。例如，如果有尝试使用和集群中现有成员相同的ID添加新成员，这个行为将在阶段1期间立即失败而不影响运行中的集群。提供类似的保存来放置错误添加新成员。如果新 etcd 成员试图在集群接受配置修改前加入集群，它将无法被集群接受。

没有围绕集群成员的明确工作流，etcd 将因意外的集群成员修改而容易受伤。例如，如果 etcd 运行在初始化系统例如 systemd，etcd 在通过成员API移除之后将被重启，并试图在启动时重新加入集群。这个循环在每次成员被通过API删除时继续，而 systemd 在失败之后被设置为重启 etcd，这是出乎意料的。

我们期待运行时重配置是极少进行的操作。我们决定让它保持明确和用户驱动以保证配置安全和保持集群总是在明确控制下平稳运行。

法定人数永久丢失需要新集群

如果集群永久丢失了它的成员的多数，需要从旧有的数据目录启动新的集群来恢复之前的状态。

从已有集群中强制删除失败成员来恢复是完全可能的。但是，我们决定不支持这个方法，因为它绕开了正常的一致性提交阶段，这是不安全的。如果要删除的成员并没有实际死亡或者是在通过同一个集群中的不同成员强制删除，etcd 将以分离的有同样ID的集群方式结束。这非常危险而之后难于调试/修改。

正确部署时，永久多数丢失的可能性非常低。但是它是一个足够严重的问题，值得特别小心。强烈建议阅读 [灾难恢复文档](#) 并在产品中使用 etcd 前为永久多数丢失做好准备。

不要为运行时重配置使用公开发现服务

公开发现服务(discovery service)仅仅应该用于启动集群。要往已有集群中添加成员，使用运行时重配置API。

发现服务设计用于在云环境下启动 etcd 集群，当所有成员的 IP 地址实现不知道时。在成功启动集群后，所有成员的 IP 地址都已知。严格说，发现服务应该不再需要。

看上去使用公开发现服务是做运行时重配置的捷径，毕竟发现服务已经有所有集群配置信息。但是，依赖公开发现服务将带来问题：

1. 它为集群的完整生命周期引入额外依赖，而不仅仅是启动时间。如果在集群和公开发现服务之间有网络问题，集群将为此受折磨。
2. 公开发现服务必须考虑在生命周期期间集群的正确运行时配置。它必须提供安全机制来避免恶劣行为，而这是很困难的。
3. 公开发现服务必须保持数以万计的集群配置。我们的公开发现服务没有为这种负载做好准备。

要有支持运行时重配置的发发现服务，最佳选择是搭建一个私有的。

etcd 网关

etcd 网关是什么

etcd 网关是一个简单的 TCP 代理，转发网络数据到 etcd 集群。网关是无状态和透明的;它既不检查客户端请求也不干涉集群应答。

网关支持多 etcd 服务器终端。当网关启动时，它随机的选择一个 etcd 服务器终端并转发所有请求到这个终端。这个终端服务锁偶请求直到网关发现一个网络失败。如果网关检测到终端失败，它将切换到其他的终端，如果可用，从而给它的客户端隐藏失败。其他重试策略，比如带权重的轮询，可能在未来支持。

何时使用 etcd 网关

每个访问 etcd 的应用必须首先要有 etcd 集群客户端终端的地址。如果在同一台服务器上的多个应用访问同一个 etcd 集群，每个应用都需要知道 etcd 集群的公告的客户端终端。如果 etcd 集群被重新配置为使用不同的终端，每个应用都需要更新它的终端列表。这个大规模的重新配置是令人生厌的，而且容易出错。

etcd 网关通过以稳定本地终端的方式来解决这个问题。典型 etcd 网关配置是在每台机器上运行网关监听在本地地址，而每个 etcd 应用连接到它本地的网关。结果是仅仅网关需要更新它的终端而不是更新每个应用。

总的来说，为了自动扩散集群终端变化，etcd 网关运行在每台机器，服务于访问同一个 etcd 集群的多个应用。

何时不使用 etcd 网关

- 提升性能

网关不是设计用来提升 etcd 集群的性能。它不提供缓存，监听联合或者批量。etcd 团队正在开发缓存代理，设计用于提升集群可扩展性。

- 运行在集群管理系统之上

高级集群管理系统比如 Kubernetes 原生支持服务发现。应用可以访问使用 DNS 名称 或者系统管理的虚拟IP地址来访问 etcd 集群。例如，kube-proxy 等价于 etcd 网关。

启动 etcd 网关

假定 etcd 集群有下列静态终端：

Name	Address	Hostname
infra0	10.0.1.10	infra0.example.com
infra1	10.0.1.11	infra1.example.com
infra2	10.0.1.12	infra2.example.com

用命令来启动 etcd 网关来使用这些静态终端：

```
$ etcd gateway start --endpoints=infra0.example.com,infra1.example.com,infra2.example.com
2016-08-16 11:21:18.867350 I | tcpproxy: ready to proxy client requests to [...]
```

或者，如果使用 DNS 做服务发现，考虑 DNS SRV entries:

```
$ dig +noall +answer SRV _etcd-client._tcp.example.com
_etcd-client._tcp.example.com. 300 IN SRV 0 0 2379 infra0.example.com.
_etcd-client._tcp.example.com. 300 IN SRV 0 0 2379 infra1.example.com.
_etcd-client._tcp.example.com. 300 IN SRV 0 0 2379 infra2.example.com.
```

```
$ dig +noall +answer infra0.example.com infra1.example.com infra2.example.com
infra0.example.com. 300 IN A 10.0.1.10
infra1.example.com. 300 IN A 10.0.1.11
infra2.example.com. 300 IN A 10.0.1.12
```

用命令来启动 etcd 网关来从 DNS SRV entries 中获取终端：

```
$ etcd gateway --discovery-srv=example.com
2016-08-16 11:21:18.867350 I | tcpproxy: ready to proxy client requests to [...]
```

在容器内运行etcd集群

下列指南展示如何使用 [static bootstrap process](#) 来用 `rkt` 和 `docker` 运行 `etcd`。

rkt

运行单节点 etcd

下列 `rkt` 运行命令将在端口 2379 上暴露 `etcd` 客户端API，而在端口 2380上暴露伙伴API。

当配置 `etcd` 时使用 `host` IP地址。

```
export NODE1=192.168.1.21
```

信任 CoreOS [App Signing Key](#).

```
sudo rkt trust --prefix coreos.com/etcd
# gpg key fingerprint is: 18AD 5014 C99E F7E3 BA5F 6CE9 50BD D3E0 FC8A 365E
```

运行 `v3.0.6` 版本的 `etcd` or 或者指定其他发布版本。

```
sudo rkt run --net=default:IP=${NODE1} coreos.com/etcd:v3.0.6 -- -name=node1 -advertis
e-client-urls=http://${NODE1}:2379 -initial-advertise-peer-urls=http://${NODE1}:2380 -
listen-client-urls=http://0.0.0.0:2379 -listen-peer-urls=http://${NODE1}:2380 -initial
-cluster=node1=http://${NODE1}:2380
```

列出集群成员。

```
etcdctl --endpoints=http://192.168.1.21:2379 member list
```

运行3节点集群

使用 `rkt` 本地搭建 3 节点的集群，使用 `-initial-cluster` 标记.

```
export NODE1=172.16.28.21
export NODE2=172.16.28.22
export NODE3=172.16.28.23
```

```
# node 1
sudo rkt run --net=default:IP=${NODE1} coreos.com/etcd:v3.0.6 -- -name=node1 -advertise-client-urls=http://${NODE1}:2379 -initial-advertise-peer-urls=http://${NODE1}:2380 -listen-client-urls=http://0.0.0.0:2379 -listen-peer-urls=http://${NODE1}:2380 -initial-cluster=node1=http://${NODE1}:2380,node2=http://${NODE2}:2380,node3=http://${NODE3}:2380

# node 2
sudo rkt run --net=default:IP=${NODE2} coreos.com/etcd:v3.0.6 -- -name=node2 -advertise-client-urls=http://${NODE2}:2379 -initial-advertise-peer-urls=http://${NODE2}:2380 -listen-client-urls=http://0.0.0.0:2379 -listen-peer-urls=http://${NODE2}:2380 -initial-cluster=node1=http://${NODE1}:2380,node2=http://${NODE2}:2380,node3=http://${NODE3}:2380

# node 3
sudo rkt run --net=default:IP=${NODE3} coreos.com/etcd:v3.0.6 -- -name=node3 -advertise-client-urls=http://${NODE3}:2379 -initial-advertise-peer-urls=http://${NODE3}:2380 -listen-client-urls=http://0.0.0.0:2379 -listen-peer-urls=http://${NODE3}:2380 -initial-cluster=node1=http://${NODE1}:2380,node2=http://${NODE2}:2380,node3=http://${NODE3}:2380
```

检验集群健康并可以到达。

```
ETCDCTL_API=3 etcdctl --endpoints=http://172.16.28.21:2379,http://172.16.28.22:2379,http://172.16.28.23:2379 endpoint-health
```

DNS

通过被本地解析器已知的 DNS 名称指向伙伴的产品集群必须挂载 [主机的 DNS 配置](#)。

Docker

为了暴露 etcd API 到 docker host 之外的客户端，使用容器的 host IP 地址。请见 [docker inspect](#) 来获取关于如何得到 IP 地址的更多细节。或者，为 `docker run` 命令指定 `--net=host` 标记来跳过放置容器在分隔的网络栈中。

```
# For each machine
ETCD_VERSION=v3.0.0
TOKEN=my-etcd-token
CLUSTER_STATE=new
NAME_1=etcd-node-0
NAME_2=etcd-node-1
NAME_3=etcd-node-2
HOST_1=10.20.30.1
HOST_2=10.20.30.2
HOST_3=10.20.30.3
CLUSTER=${NAME_1}=http://${HOST_1}:2380,${NAME_2}=http://${HOST_2}:2380,${NAME_3}=http://${HOST_3}:2380

# For node 1
THIS_NAME=${NAME_1}
THIS_IP=${HOST_1}
sudo docker run --net=host --name etcd quay.io/coreos/etcd:${ETCD_VERSION} \
  /usr/local/bin/etcd \
  --data-dir=data.etcd --name ${THIS_NAME} \
  --initial-advertise-peer-urls http://${THIS_IP}:2380 --listen-peer-urls http://${THIS_IP}:2380 \
  --advertise-client-urls http://${THIS_IP}:2379 --listen-client-urls http://${THIS_IP}:2379 \
  --initial-cluster ${CLUSTER} \
  --initial-cluster-state ${CLUSTER_STATE} --initial-cluster-token ${TOKEN}

# For node 2
THIS_NAME=${NAME_2}
THIS_IP=${HOST_2}
sudo docker run --net=host --name etcd quay.io/coreos/etcd:${ETCD_VERSION} \
  /usr/local/bin/etcd \
  --data-dir=data.etcd --name ${THIS_NAME} \
  --initial-advertise-peer-urls http://${THIS_IP}:2380 --listen-peer-urls http://${THIS_IP}:2380 \
  --advertise-client-urls http://${THIS_IP}:2379 --listen-client-urls http://${THIS_IP}:2379 \
  --initial-cluster ${CLUSTER} \
  --initial-cluster-state ${CLUSTER_STATE} --initial-cluster-token ${TOKEN}

# For node 3
THIS_NAME=${NAME_3}
THIS_IP=${HOST_3}
sudo docker run --net=host --name etcd quay.io/coreos/etcd:${ETCD_VERSION} \
  /usr/local/bin/etcd \
  --data-dir=data.etcd --name ${THIS_NAME} \
  --initial-advertise-peer-urls http://${THIS_IP}:2380 --listen-peer-urls http://${THIS_IP}:2380 \
  --advertise-client-urls http://${THIS_IP}:2379 --listen-client-urls http://${THIS_IP}:2379 \
  --initial-cluster ${CLUSTER} \
  --initial-cluster-state ${CLUSTER_STATE} --initial-cluster-token ${TOKEN}
```


为了使用 API 版本3 来运行 `etcdctl`：

```
docker exec etcd /bin/sh -c "export ETCDCTL_API=3 && /usr/local/bin/etcdctl put foo bar"
```

裸机

为了在裸机上提供 3 节点 etcd 集群，可以在 [baremetal repo](#) 中搜索有用的案例。

配置标记

etcd 可以通过命令行标记和环境变量来配置。命令行上设置的选项优先于环境变量。

对于标记 `--my-flag` 环境变量的格式是 `ETCD_MY_FLAG`。适用于所有标记。

正式的etcd端口是 2379 用于客户端连接，而 2380 用于伙伴通讯。etcd 端口可以设置为接受 TLS 通讯，non-TLS 通讯，或者同时有 TLS 和 non-TLS 通讯。

为了在 linux 启动试使用自定义设置自动启动 etcd，强烈推荐使用 `systemd`单元。

成员标记

--name

- 成员的可读性的名字.
- 默认: "default"
- 环境变量: ETCD_NAME
- 这个值被作为这个节点自己的入口中被引用，在 `--initial-cluster` 标记(例如, `default=http://localhost:2380`)中列出。如果使用 [static bootstrapping](#),这需要匹配在标记中使用的key。当使用发现时，每个成员必须有唯一名字。`Hostname` 或 `machine-id` 可以是一个好选择。

--data-dir

- 到数据目录的路径.
- 默认: "\${name}.etcd"
- 环境变量: ETCD_DATA_DIR

--wal-dir

- 到专用的 wal 目录的路径。如果这个标记被设置，etcd将写 WAL 文件到 walDIR 而不是 dataDIR。这容许使用专门的硬盘，并帮助避免日志和其他IO操作之间的IO竞争。
- 默认: ""
- 环境变量: ETCD_WAL_DIR

--snapshot-count

- 触发快照到硬盘的已提交事务的数量.

- 默认: "10000"
- 环境变量: ETCD_SNAPSHOT_COUNT

--heartbeat-interval

- 心跳间隔时间 (单位 毫秒).
- 默认: "100"
- 环境变量: ETCD_HEARTBEAT_INTERVAL

--election-timeout

- 选举的超时时间(单位 毫秒). 阅读 [Documentation/tuning.md](#) 得到更多详情.
- 默认: "1000"
- 环境变量: ETCD_ELECTION_TIMEOUT

--listen-peer-urls

用于监听伙伴通讯的URL列表。这个标记告诉 etcd 在特定的 scheme://IP:port 组合上从它的伙伴接收进来的请求。scheme 可是 http 或者 https。如果IP被指定为0.0.0.0,etcd 在所有接口上监听给定端口。如果给定IP地址和端口，etcd 将监听在给定端口和接口上。多个URL可以用来指定多个地址和端口来监听。etcd将从任何列出来的地址和端口上应答请求。

- 默认: "[http://localhost:2380](#)"
- 环境变量: ETCD_LISTEN_PEER_URLS
- 例子: "[http://10.0.0.1:2380](#)"
- 无效例子: "[http://example.com:2380](#)" (对于绑定域名无效)

--listen-client-urls

用于监听客户端通讯的URL列表。这个标记告诉 etcd 在特定的 scheme://IP:port 组合上从客户端接收进来的请求。scheme 可是 http 或者 https。如果IP被指定为 0.0.0.0,etcd 在所有接口上监听给定端口。如果给定IP地址和端口，etcd 将监听在给定端口和接口上。多个 URL 可以用来指定多个地址和端口来监听。etcd 将从任何列出来的地址和端口上应答请求。

- 默认: "[http://localhost:2379](#)"
- 环境变量: ETCD_LISTEN_CLIENT_URLS
- 例子: "[http://10.0.0.1:2379](#)"
- 无效例子: "[http://example.com:2379](#)" (对于绑定域名无效)

--max-snapshots

- 保持的快照文件的最大数量 (0 表示不限制)

- 默认: 5
- 环境变量: ETCD_MAX_SNAPSHOTS
- 对于 windows 用户默认不限制，而且推荐手工降低到5（或者某些安全偏好）。

--max-wals

- 保持的 wal 文件的最大数量 (0 表示不限制)
- 默认: 5
- 环境变量: ETCD_MAX_WALS
- 对于windows用户默认不限制，而且推荐手工降低到5（或者某些安全偏好）。

--cors

- 逗号分割的 origin 白名单，用于 CORS (cross-origin resource sharing/跨 origin 资源共享).
- 默认: none
- 环境变量: ETCD_CORS

集群标记

`--initial` 前缀标记用于启动([static bootstrap](#), [[discovery-service bootstrap](#)]) (clustering.md#discovery) 或 [runtime reconfiguration](#)) 新成员, 然后当重新启动一个已有的成员时被忽略。

`--discovery` 前缀标记在使用[发现服务](#)需要设置。

--initial-advertise-peer-urls

列出这个成员的伙伴 URL 以便通告给集群的其他成员。这些地方用于在集群中通讯 etcd 数据。至少有一个必须对所有集群成员可以路由的。这些 URL 可以包含域名。

- 默认: "<http://localhost:2380>"
- 环境变量: ETCD_INITIAL_ADVERTISE_PEER_URLS
- 例子: "<http://example.com:2380>, <http://10.0.0.1:2380>"

--initial-cluster

为启动初始化集群配置。

- 默认: "default=<http://localhost:2380>"
- 环境变量: ETCD_INITIAL_CLUSTER

- **key**是每个提供的节点的 `--name` 标记的值. 默认为这个 **key** 使用 `default` 因为这是 `--name` 标记的默认值.

--initial-cluster-state

初始化集群状态("new" or "existing")。在初始化静态(initial static)或者 DNS 启动 (DNS bootstrapping) 期间为所有成员设置为 `new` 。如果这个选项被设置为 `existing` , `etcd` 将试图加入已有的集群。如果设置为错误的值, `etcd` 将尝试启动但安全失败。

- 默认: "new"
- 环境变量: ETCD_INITIAL_CLUSTER_STATE

--initial-cluster-token

在启动期间用于 `etcd` 集群的初始化集群记号(cluster token)。

- 默认: "etcd-cluster"
- 环境变量: ETCD_INITIAL_CLUSTER_TOKEN

--advertise-client-urls

列出这个成员的客户端URL, 通告给集群中的其他成员。这些 URL 可以包含域名。

- 默认: "<http://localhost:2379>"
- 环境变量: ETCD_ADVERTISE_CLIENT_URLS
- 例子: "<http://example.com:2379>, <http://10.0.0.1:2379>"

小心, 如果来自集群成员的通告 URL 比如 <http://localhost:2379> 正在使用 `etcd` 的 proxy 特性。这将导致循环, 因为代理将转发请求给它自己直到它的资源(内存, 文件描述符)最终耗尽。

--discovery

用于启动集群的发现URL。

- 默认: none
- 环境变量: ETCD_DISCOVERY

--discovery-srv

用于启动集群的 DNS srv 域名。

- 默认: none
- 环境变量: ETCD_DISCOVERY_SRV

--discovery-fallback

当发现服务失败时的期待行为("exit" 或 "proxy"). "proxy" 仅支持 v2 API.

- 默认: "proxy"
- 环境变量: ETCD_DISCOVERY_FALLBACK

--discovery-proxy

用于请求到发现服务的 HTTP 代理。

- 默认: none
- 环境变量: ETCD_DISCOVERY_PROXY

--strict-reconfig-check

拒绝将导致法定人数丢失的重配置请求。

- 默认: false
- 环境变量: ETCD_STRICT_RECONFIG_CHECK

--auto-compaction-retention

自动压缩用于 mvcc 键值存储的保持力(注：应该指多版本保存)，单位小时。0 表示关闭自动压缩。

- 默认: 0
- 环境变量: ETCD_AUTO_COMPACTION_RETENTION

注：对于服务注册等只保存运行时动态信息的场合，建议开启。完全没有理由损失存储空间和效率来保存之前的版本信息。推荐设置为1,每小时压缩一次。

Proxy flags

--proxy 前缀标记配置 etcd 以 [代理模式](#) 运行. "proxy" 仅支持 v2 API.

--proxy

代理模式设置("off", "readonly" or "on").

- 默认: "off"
- 环境变量: ETCD_PROXY

--proxy-failure-wait

在被重新考虑之前，终端将被视为失败状态的时间(单位 毫秒)，用于被代理的请求。

- 默认: 5000
- 环境变量: ETCD_PROXY_FAILURE_WAIT

--proxy-refresh-interval

终端刷新闻隔时间(单位 毫秒)

- 默认: 30000
- 环境变量: ETCD_PROXY_REFRESH_INTERVAL

--proxy-dial-timeout

请求的拨号(dial)超时时间(单位 毫秒)，或者 0 禁用超时。

- 默认: 1000
- 环境变量 ETCD_PROXY_DIAL_TIMEOUT

--proxy-write-timeout

写操作的超时时间(单位 毫秒)，或者 0 禁用超时。

- 默认: 5000
- 环境变量: ETCD_PROXY_WRITE_TIMEOUT

--proxy-read-timeout

读操作的超时时间(单位 毫秒)，或者 0 禁用超时。

不要修改这个值，如果在使用 watch，因为 watch 将使用 long polling 请求。

- 默认: 0
- 环境变量: ETCD_PROXY_READ_TIMEOUT

安全标记

安全标记用于帮助 [搭建安全 etcd 集群](#)。

--ca-file [弃用]

客户端服务器 TLS 证书文件的路径。 `--ca-file ca.crt` 可以被 `--trusted-ca-file ca.crt --client-cert-auth` 替代，而 `etcd` 同样工作。

- 默认: none
- 环境变量: `ETCD_CA_FILE`

--cert-file

客户端服务器 TLS 证书文件的路径。

- 默认: none
- 环境变量: `ETCD_CERT_FILE`

--key-file

客户端服务器 TLS key 文件的路径。

- 默认: none
- 环境变量: `ETCD_KEY_FILE`

--client-cert-auth

开启客户端证书认证。

- 默认: false
- 环境变量: `ETCD_CLIENT_CERT_AUTH`

--trusted-ca-file

客户端服务器 TLS 信任证书文件的路径。

- 默认: none
- 环境变量: `ETCD_TRUSTED_CA_FILE`

--auto-tls

使用生成证书的客户端 TLS。

- 默认: false
- 环境变量: `ETCD_AUTO_TLS`

--peer-ca-file [弃用]

peer server TLS 证书文件的路径. `--peer-ca-file ca.crt` 可以被 `--peer-trusted-ca-file ca.crt --peer-client-cert-auth` 替代, 而 `etcd` 同样工作.

- 默认: none
- 环境变量: `ETCD_PEER_CA_FILE`

--peer-cert-file

peer server TLS 证书文件的路径.

- 默认: none
- 环境变量: `ETCD_PEER_CERT_FILE`

--peer-key-file

peer server TLS key 文件的路径.

- 默认: none
- 环境变量: `ETCD_PEER_KEY_FILE`

--peer-client-cert-auth

开启 peer client 证书验证.

- 默认: false
- 环境变量: `ETCD_PEER_CLIENT_CERT_AUTH`

--peer-trusted-ca-file

peer server TLS 信任证书文件路径.

- 默认: none
- 环境变量: `ETCD_PEER_TRUSTED_CA_FILE`

--peer-auto-tls

使用生成证书的peer TLS。

- 默认: false
- 环境变量: `ETCD_PEER_AUTO_TLS`

日志标记

--debug

设置所有子包的默认日志级别为 DEBUG

- 默认: false (所有包为 INFO)
- 环境变量: ETCD_DEBUG

--log-package-levels

设置个人 etcd 子包为指定日志级别。例如 `etcdserver=WARNING,security=DEBUG`

- 默认: none (所有包为 INFO)
- 环境变量: ETCD_LOG_PACKAGE_LEVELS

不安全的标记

请谨慎使用不安全标记，因为它将打破一致性协议提供的保证。

例如，它可能惊慌，如果集群中的其他成员还活着。

当使用这些标记时，遵循操作指南。

--force-new-cluster

强制创建新的单一成员的集群。它提交配置修改来强制移除集群中的所有现有成员然后添加自身。当 [restore a backup](#) 时需要设置。

- 默认: false
- 环境变量: ETCD_FORCE_NEW_CLUSTER

其他标记

--version

打印版本并退出。

- 默认: false

--config-file

从文件中装载服务器配置。

- 默认: none

分析标记

--enable-pprof

通过 HTTP 服务器开启运行时分析数据。地址是 client URL + "/debug/pprof/"

- 默认: false

--metrics

- 为导出的度量，设置详情的等级，指定 'extensive' 来包含柱状图
- 默认: basic

gRPC proxy

TBD!

This is a pre-alpha feature, we are looking for early feedback.

The gRPC proxy is a stateless etcd reverse proxy operating at the gRPC layer (L7). The proxy is designed to reduce the total processing load on the core etcd cluster. For horizontal scalability, it coalesces watch and lease API requests. To protect the cluster against abusive clients, it caches key range requests.

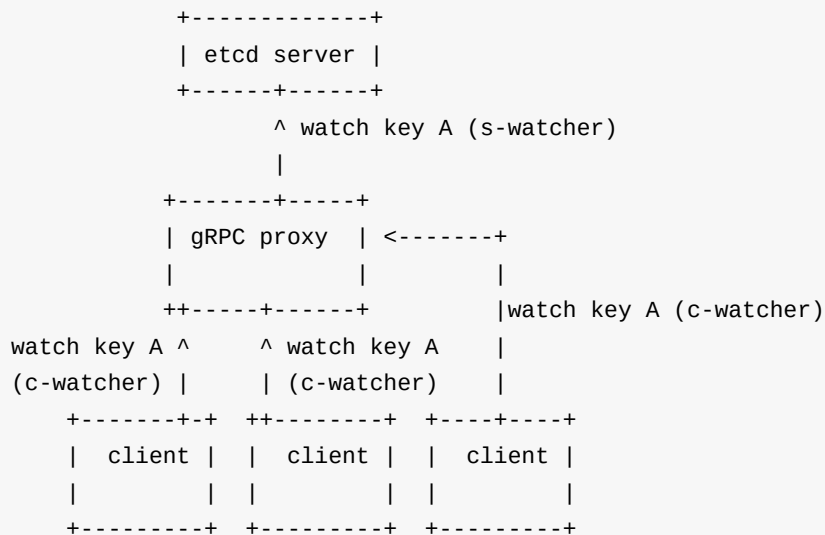
The gRPC proxy supports multiple etcd server endpoints. When the proxy starts, it randomly picks one etcd server endpoint to use. This endpoint serves all requests until the proxy detects an endpoint failure. If the gRPC proxy detects an endpoint failure, it switches to a different endpoint, if available, to hide failures from its clients. Other retry policies, such as weighted round-robin, may be supported in the future.

Scalable watch API

The gRPC proxy coalesces multiple client watchers (`c-watchers`) on the same key or range into a single watcher (`s-watcher`) connected to an etcd server. The proxy broadcasts all events from the `s-watcher` to its `c-watchers` .

Assuming N clients watch the same key, one gRPC proxy can reduce the watch load on the etcd server from N to 1. Users can deploy multiple gRPC proxies to further distribute server load.

In the following example, three clients watch on key A. The gRPC proxy coalesces the three watchers, creating a single watcher attached to the etcd server.



Limitations

To effectively coalesce multiple client watchers into a single watcher, the gRPC proxy coalesces new `c-watchers` into an existing `s-watcher` when possible. This coalesced `s-watcher` may be out of sync with the etcd server due to network delays or buffered undelivered events. When the watch revision is unspecified, the gRPC proxy will not guarantee the `c-watcher` will start watching from the most recent store revision. For example, if a client watches from an etcd server with revision 1000, that watcher will begin at revision 1000. If a client watches from the gRPC proxy, may begin watching from revision 990.

Similar limitations apply to cancellation. When the watcher is cancelled, the etcd server's revision may be greater than the cancellation response revision.

These two limitations should not cause problems for most use cases. In the future, there may be additional options to force the watcher to bypass the gRPC proxy for more accurate revision responses.

Scalable lease API

TODO

Abusive clients protection

The gRPC proxy caches responses for requests when it does not break consistency requirements. This can protect the etcd server from abusive clients in tight for loops.

Start etcd gRPC proxy

Consider an etcd cluster with the following static endpoints:

Name	Address	Hostname
infra0	10.0.1.10	infra0.example.com
infra1	10.0.1.11	infra1.example.com
infra2	10.0.1.12	infra2.example.com

Start the etcd gRPC proxy to use these static endpoints with the command:

```
$ etcd grpc-proxy start --endpoints=infra0.example.com,infra1.example.com,infra2.example.com --listen-addr=127.0.0.1:2379
```

The etcd gRPC proxy starts and listens on port 8080. It forwards client requests to one of the three endpoints provided above.

Sending requests through the proxy:

```
$ ETCDCTL_API=3 ./etcdctl --endpoints=127.0.0.1:2379 put foo bar
OK
$ ETCDCTL_API=3 ./etcdctl --endpoints=127.0.0.1:2379 get foo
foo
bar
```

支持平台

当前支持

下面的表单列出了常见架构和系统的 etcd 支持状态：

架构	操作系统	状态	维护者
amd64	Darwin	实现性	etcd maintainers
amd64	Linux	稳定	etcd maintainers
amd64	Windows	实现性	
arm64	Linux	实现性	@glevand
arm	Linux	不稳定	
386	Linux	不稳定	

- etcd-维护者被列举在 <https://github.com/coreos/etcd/blob/master/MAINTAINERS>.

试验性的平台似乎在不断练习中工作，并在 etcd 中有一些平台特有代码，而没有完全遵守稳定支持策略。不稳定平台有轻度测试，那是比试验性少。为列出的架构和操作系统当前不支持，请当心！

支持新平台

对于 etcd 官方支持新的稳定平台，有一些要求是必须的，以保证可接受的质量：

1. 一个这个平台的 "官方" 的维护者，有清晰的动力;必须有人负责照看这个平台。
2. 搭建构建的CI; etcd 必须编译
3. 搭建用于运行单元测试的CI;etcd 必须通过简单的测试。
4. 搭建CI (TravisCI, SemaphoreCI 或 Jenkins) 用于运行集成测试;etcd必须通过加强测试。
5. (可选) 搭建功能测试集群; etcd 集群应该能通过压力测试。

32-位 和其他未支持系统

由于go runtime 的 bug，etcd 在32位系统上有众所周知的问题。阅读 [Go issue](#) 和 [atomic package](#) 来获取详细信息。

为了避免不经意的运行可能不稳定的 etcd 服务器，在不稳定或者未支持架构上的 etcd 将打印警告信息并立即退出，如果环境变量 `ETCD_UNSUPPORTED_ARCH` 没有设置为目标架构。

当前仅有 **amd64** 架构被 `etcd` 官方支持。

Hardware recommendations

TBD

etcd usually runs well with limited resources for development or testing purposes; it's common to develop with etcd on a laptop or a cheap cloud machine. However, when running etcd clusters in production, some hardware guidelines are useful for proper administration. These suggestions are not hard rules; they serve as a good starting point for a robust production deployment. As always, deployments should be tested with simulated workloads before running in production.

CPUs

Few etcd deployments require a lot of CPU capacity. Typical clusters need two to four cores to run smoothly. Heavily loaded etcd deployments, serving thousands of clients or tens of thousands of requests per second, tend to be CPU bound since etcd can serve requests from memory. Such heavy deployments usually need eight to sixteen dedicated cores.

Memory

etcd has a relatively small memory footprint but its performance still depends on having enough memory. An etcd server will aggressively cache key-value data and spends most of the rest of its memory tracking watchers. Typically 8GB is enough. For heavy deployments with thousands of watchers and millions of keys, allocate 16GB to 64GB memory accordingly.

Disks

Fast disks are the most critical factor for etcd deployment performance and stability.

A slow disk will increase etcd request latency and potentially hurt cluster stability. Since etcd's consensus protocol depends on persistently storing metadata to a log, a majority of etcd cluster members must write every request down to disk. Additionally, etcd will also incrementally checkpoint its state to disk so it can truncate this log. If these writes take too long, heartbeats may time out and trigger an election, undermining the stability of the cluster.

etcd is very sensitive to disk write latency. Typically 50 sequential IOPS (e.g., a 7200 RPM disk) is required. For heavily loaded clusters, 500 sequential IOPS (e.g., a typical local SSD or a high performance virtualized block device) is recommended. Note that most cloud providers publish concurrent IOPS rather than sequential IOPS; the published concurrent IOPS can be 10x greater than the sequential IOPS. To measure actual sequential IOPS, we suggest using a disk benchmarking tool such as [diskbench](#) or [fio](#).

etcd requires only modest disk bandwidth but more disk bandwidth buys faster recovery times when a failed member has to catch up with the cluster. Typically 10MB/s will recover 100MB data within 15 seconds. For large clusters, 100MB/s or higher is suggested for recovering 1GB data within 15 seconds.

When possible, back etcd's storage with a SSD. A SSD usually provides lower write latencies and with less variance than a spinning disk, thus improving the stability and reliability of etcd. If using spinning disk, get the fastest disks possible (15,000 RPM). Using RAID 0 is also an effective way to increase disk speed, for both spinning disks and SSD. With at least three cluster members, mirroring and/or parity variants of RAID are unnecessary; etcd's consistent replication already gets high availability.

Network

Multi-member etcd deployments benefit from a fast and reliable network. In order for etcd to be both consistent and partition tolerant, an unreliable network with partitioning outages will lead to poor availability. Low latency ensures etcd members can communicate fast. High bandwidth can reduce the time to recover a failed etcd member. 1GbE is sufficient for common etcd deployments. For large etcd clusters, a 10GbE network will reduce mean time to recovery.

Deploy etcd members within a single data center when possible to avoid latency overheads and lessen the possibility of partitioning events. If a failure domain in another data center is required, choose a data center closer to the existing one. Please also read the [tuning](#) documentation for more information on cross data center deployment.

Example hardware configurations

Here are a few example hardware setups on AWS and GCE environments. As mentioned before, but must be stressed regardless, administrators should test an etcd deployment with a simulated workload before putting it into production.

Note that these configurations assume these machines are totally dedicated to etcd. Running other applications along with etcd on these machines may cause resource contentions and lead to cluster instability.

Small cluster

A small cluster serves fewer than 100 clients, fewer than 200 of requests per second, and stores no more than 100MB of data.

Example application workload: A 50-node Kubernetes cluster

Provider	Type	vCPUs	Memory (GB)	Max concurrent IOPS	Disk bandwidth (MB/s)
AWS	m4.large	2	8	3600	56.25
GCE	n1-standard-1 + 50GB PD SSD	2	7.5	1500	25

Medium cluster

A medium cluster serves fewer than 500 clients, fewer than 1,000 of requests per second, and stores no more than 500MB of data.

Example application workload: A 250-node Kubernetes cluster

Provider	Type	vCPUs	Memory (GB)	Max concurrent IOPS	Disk bandwidth (MB/s)
AWS	m4.xlarge	4	16	6000	93.75
GCE	n1-standard-4 + 150GB PD SSD	4	15	4500	75

Large cluster

A large cluster serves fewer than 1,500 clients, fewer than 10,000 of requests per second, and stores no more than 1GB of data.

Example application workload: A 1,000-node Kubernetes cluster

Provider	Type	vCPUs	Memory (GB)	Max concurrent IOPS	Disk bandwidth (MB/s)
AWS	m4.2xlarge	8	32	8000	125
GCE	n1-standard-8 + 250GB PD SSD	8	30	7500	125

xLarge cluster

An xLarge cluster serves more than 1,500 clients, more than 10,000 of requests per second, and stores more than 1GB data.

Example application workload: A 3,000 node Kubernetes cluster

Provider	Type	vCPUs	Memory (GB)	Max concurrent IOPS	Disk bandwidth (MB/s)
AWS	m4.4xlarge	16	64	16,000	250
GCE	n1-standard-16 + 500GB PD SSD	16	60	15,000	250

性能

理解性能

etcd 提供稳定的，持续的高性能。两个定义性能的因素：延迟(latency)和吞吐量(throughput)。延迟是完成操作的时间。吞吐量是在某个时间期间之内完成操作的总数量。当 etcd 接收并发客户端请求时，通常平均延迟随着总体吞吐量增加而增加。在通常的云环境，比如 Google Compute Engine (GCE) 标准的 `n-4` 或者 AWS 上相当的机器类型，一个三成员 etcd 集群在轻负载下可以在低于1毫秒内完成一个请求，并在重负载下可以每秒完成超过 30000 个请求。

etcd 使用 Raft 一致性算法来在成员之间复制请求并达成一致。一致性性能，特别是提交延迟，受限于两个物理约束：网络IO延迟和磁盘IO延迟。完成一个etcd请求的最小时间是成员之间的网络往返时延(Round Trip Time / RTT)，加需要提交数据到持久化存储的 `fdatasync` 时间。在一个数据中心内的 RTT 可能有数百毫秒。在美国典型的 RTT 是大概 50ms, 而在大陆之间可以慢到400ms. 旋转硬盘(注：指传统机械硬盘)的典型 `fdatasync` 延迟是大概 10ms。对于 SSD 硬盘, 延迟通常低于 1ms. 为了提高吞吐量, etcd 将多个请求打包在一起并提交给 Raft。这个批量策略让 etcd 在重负载时获得高吞吐量。

有其他子系统影响到 etcd 的整体性能。每个序列化的 etcd 请求必须通过 etcd 的 boltdb支持的(boltdb-backed) MVCC 存储引擎,它通常需要10微秒来完成。etcd 定期递增快照它最近实施的请求，将他们和之前在磁盘上的快照合并。这个过程可能导致延迟尖峰(latency spike)。虽然在SSD上这通常不是问题，在HDD上它可能加倍可观察到的延迟。而且，进行中的压缩可以影响 etcd 的性能。幸运的是，压缩通常无足轻重，因为压缩是错开的，因此它不和常规请求竞争资源。RPC 系统，gRPC，为 etcd 提供定义良好，可扩展的 API，但是它也引入了额外的延迟，尤其是本地读取。

评测

可以通过 etcd 自带的 `benchmark` CLI 工具来评测 etcd 的性能。

对于某些基线性能数字，我们考虑的是3成员 etcd 集群，带有下列硬件配置：

- Google Cloud Compute Engine
- 3 台机器，8 vCPUs + 16GB Memory + 50GB SSD
- 1 台机器(客户端)，16 vCPUs + 30GB Memory + 50GB SSD
- Ubuntu 15.10
- etcd v3 master 分支 (commit SHA d8f325d), Go 1.6.2

使用这些配置，etcd 能近似的写入：

key的数量	Key的大小	Value的大小	连接数量	客户端数量	目标 etcd 服务器	平均写入 QPS	每请求平均延迟	内存
10,000	8	256	1	1	leader only	525	2ms	35 MB
100,000	8	256	100	1000	leader only	25,000	30ms	35 MB
100,000	8	256	100	1000	all members	33,000	25ms	35 MB

注：key和value的大小单位是 字节 / bytes

采样命令是：

```
# 假定 IP_1 是 leader, 写入请求发到 leader
benchmark --endpoints={IP_1} --conns=1 --clients=1 \
  put --key-size=8 --sequential-keys --total=10000 --val-size=256
benchmark --endpoints={IP_1} --conns=100 --clients=1000 \
  put --key-size=8 --sequential-keys --total=100000 --val-size=256

# 写入发到所有成员
benchmark --endpoints={IP_1},{IP_2},{IP_3} --conns=100 --clients=1000 \
  put --key-size=8 --sequential-keys --total=100000 --val-size=256
```

为了一致性，线性化(Linearizable)读取请求要通过集群成员的法定人数来获取最新的数据。串行化(Serializable)读取请求比线性化读取要廉价一些，因为他们是通过任意单台 etcd 服务器来提供服务，而不是成员的法定人数，代价是可能提供过期数据。etcd 可以读取：

请求数量	Key大小	Value大小	连接数量	客户端数量	一致性	每请求平均延迟	平均读取 QPS
10,000	8	256	1	1	Linearizable	2ms	560
10,000	8	256	1	1	Serializable	0.4ms	7,500
100,000	8	256	100	1000	Linearizable	15ms	43,000
100,000	8	256	100	1000	Serializable	9ms	93,000

采样命令是：

```
# Linearizable 读取请求
benchmark --endpoints={IP_1},{IP_2},{IP_3} --conns=1 --clients=1 \
    range YOUR_KEY --consistency=1 --total=10000
benchmark --endpoints={IP_1},{IP_2},{IP_3} --conns=100 --clients=1000 \
    range YOUR_KEY --consistency=1 --total=100000

# Serializable 读取请求，使用每个成员然后将数字加起来
for endpoint in {IP_1} {IP_2} {IP_3}; do
    benchmark --endpoints=$endpoint --conns=1 --clients=1 \
        range YOUR_KEY --consistency=s --total=10000
done
for endpoint in {IP_1} {IP_2} {IP_3}; do
    benchmark --endpoints=$endpoint --conns=100 --clients=1000 \
        range YOUR_KEY --consistency=s --total=100000
done
```

当在新的环境中第一次搭建 **etcd** 集群时，我们鼓励运行评测测试来保证集群达到足够的性能；集群延迟和吞吐量对微小的环境差异会很敏感。

Tuning

TBD

The default settings in etcd should work well for installations on a local network where the average network latency is low. However, when using etcd across multiple data centers or over networks with high latency, the heartbeat interval and election timeout settings may need tuning.

The network isn't the only source of latency. Each request and response may be impacted by slow disks on both the leader and follower. Each of these timeouts represents the total time from request to successful response from the other machine.

Time parameters

The underlying distributed consensus protocol relies on two separate time parameters to ensure that nodes can handoff leadership if one stalls or goes offline. The first parameter is called the *Heartbeat Interval*. This is the frequency with which the leader will notify followers that it is still the leader. For best practices, the parameter should be set around round-trip time between members. By default, etcd uses a `100ms` heartbeat interval.

The second parameter is the *Election Timeout*. This timeout is how long a follower node will go without hearing a heartbeat before attempting to become leader itself. By default, etcd uses a `1000ms` election timeout.

Adjusting these values is a trade off. The value of heartbeat interval is recommended to be around the maximum of average round-trip time (RTT) between members, normally around 0.5-1.5x the round-trip time. If heartbeat interval is too low, etcd will send unnecessary messages that increase the usage of CPU and network resources. On the other side, a too high heartbeat interval leads to high election timeout. Higher election timeout takes longer time to detect a leader failure. The easiest way to measure round-trip time (RTT) is to use [PING utility](#).

The election timeout should be set based on the heartbeat interval and average round-trip time between members. Election timeouts must be at least 10 times the round-trip time so it can account for variance in the network. For example, if the round-trip time between members is 10ms then the election timeout should be at least 100ms.

The election timeout should be set to at least 5 to 10 times the heartbeat interval to account for variance in leader replication. For a heartbeat interval of 50ms, set the election timeout to at least 250ms - 500ms.

The upper limit of election timeout is 50000ms (50s), which should only be used when deploying a globally-distributed etcd cluster. A reasonable round-trip time for the continental United States is 130ms, and the time between US and Japan is around 350-400ms. If the network has uneven performance or regular packet delays/loss then it is possible that a couple of retries may be necessary to successfully send a packet. So 5s is a safe upper limit of global round-trip time. As the election timeout should be an order of magnitude bigger than broadcast time, in the case of ~5s for a globally distributed cluster, then 50 seconds becomes a reasonable maximum.

The heartbeat interval and election timeout value should be the same for all members in one cluster. Setting different values for etcd members may disrupt cluster stability.

The default values can be overridden on the command line:

```
# Command line arguments:
$ etcd --heartbeat-interval=100 --election-timeout=500

# Environment variables:
$ ETCD_HEARTBEAT_INTERVAL=100 ETCD_ELECTION_TIMEOUT=500 etcd
```

The values are specified in milliseconds.

Snapshots

etcd appends all key changes to a log file. This log grows forever and is a complete linear history of every change made to the keys. A complete history works well for lightly used clusters but clusters that are heavily used would carry around a large log.

To avoid having a huge log etcd makes periodic snapshots. These snapshots provide a way for etcd to compact the log by saving the current state of the system and removing old logs.

Snapshot tuning

Creating snapshots can be expensive so they're only created after a given number of changes to etcd. By default, snapshots will be made after every 10,000 changes. If etcd's memory usage and disk usage are too high, try lowering the snapshot threshold by setting the following on the command line:

```
# Command line arguments:
$ etcd --snapshot-count=5000

# Environment variables:
$ ETCD_SNAPSHOT_COUNT=5000 etcd
```

Network

If the etcd leader serves a large number of concurrent client requests, it may delay processing follower peer requests due to network congestion. This manifests as send buffer error messages on the follower nodes:

```
dropped MsgProp to 247ae21ff9436b2d since streamMsg's sending buffer is full
dropped MsgAppResp to 247ae21ff9436b2d since streamMsg's sending buffer is full
```

These errors may be resolved by prioritizing etcd's peer traffic over its client traffic. On Linux, peer traffic can be prioritized by using the traffic control mechanism:

```
tc qdisc add dev eth0 root handle 1: prio bands 3
tc filter add dev eth0 parent 1: protocol ip prio 1 u32 match ip sport 2380 0xffff flo
wid 1:1
tc filter add dev eth0 parent 1: protocol ip prio 1 u32 match ip dport 2380 0xffff flo
wid 1:1
tc filter add dev eth0 parent 1: protocol ip prio 2 u32 match ip sport 2739 0xffff flo
wid 1:1
tc filter add dev eth0 parent 1: protocol ip prio 2 u32 match ip dport 2739 0xffff flo
wid 1:1
```

安全模式

etcd 支持自动 TLS 以及通过客户端证书的身份验证, 包括客户端到服务器以及对等 (服务器到服务器/集群) 的通信。

要开始运行, 首先要为成员设置 CA 证书和已签名的密钥对。建议为集群中的每个成员创建并签署一个新的密钥对。

为方便起见, [cfssl](#) 工具为证书生成提供了简单的界面, 我们使用 [这里](#) 的工具提供了示例。或者, 尝试[生成自签名密钥对的指南](#)。

基本设置

etcd 通过命令行标志或环境变量来设置几个与证书相关的配置选项:

客户端到服务器端通讯:

`--cert-file=<path>`: 用于到 etcd 的 SSL / TLS 连接的证书。当设置此选项时, `advertise-client-urls` 可以使用 HTTPS 模式。

`--key-file=<path>`: 证书的密钥, 必须是不加密的。

`--client-cert-auth`: 当这个选项被设置时, etcd 将为受信任CA签名的客户端证书检查所有的传入的 HTTPS 请求, 不能提供有效客户端证书的请求将会失败。

`--trusted-ca-file=<path>`: 受信任的认证机构

`--auto-tls`: 为客户端的 TLS 连接, 使用自动生成的自签名证书

对等通讯 (服务器到服务器 / 集群):

对等选项的工作方式与客户端到服务器的选项相同:

`--peer-cert-file=<path>`: 用于对等体之间的 SSL / TLS 连接的证书。这将用于在对等地址上监听以及向其他对等体发送请求

`--peer-key-file=<path>`: 证书的密钥, 必须是不加密的。

`--peer-client-cert-auth`: 当这个选项被设置时, etcd 将为受信任CA签名的客户端证书检查所有的传入的对等请求。

`--peer-trusted-ca-file=<path>`: 受信任的认证机构。

`--peer-auto-tls`: 为对等体之间的 TLS 连接使用自动生成的自签名证书

如果提供了客户端到服务器或对等证书，则必须设置密钥。所有这些配置选项也可以通过环境变量“ETCD_CA_FILE”，“ETCD_PEER_CA_FILE”等提供。

示例 1: 用HTTPS的客户端到服务器端传输安全

为此，准备好CA证书（ `ca.crt` ）和签名密钥对（ `server.crt` , `server.key` ）。

Let us configure etcd to provide simple HTTPS transport security step by step:

让我们一步一步配置 etcd 来提供简单的 HTTPS 传输安全：

```
$ etcd --name infra0 --data-dir infra0 \
  --cert-file=/path/to/server.crt --key-file=/path/to/server.key \
  --advertise-client-urls=https://127.0.0.1:2379 --listen-client-urls=https://127.0.0.1:2379
```

应该可以启动，可以通过使用 HTTPS 访问 etcd 来测试配置：

```
$ curl --cacert /path/to/ca.crt https://127.0.0.1:2379/v2/keys/foo -XPUT -d value=bar -v
```

该命令应该显示握手成功。由于我们用自己的证书颁发机构使用自签名证书，CA必须使用 `-cacert` 选项传递给curl。另一种可能性是将CA证书添加到系统的可信证书目录（通常位于 `/etc/pki/tls/certs` 或 `/etc/ssl/certs`）中。

OSX 10.9+ 用户: curl 7.30.0 在 OSX 10.9+ 不能理解通过命令行传递的证书. 取而代之的，将虚拟 `ca.crt` 直接导入 `keychain` 或给 curl 添加 `-k` 标志来忽略错误。要测试没有 `-k` 标志，运行 `open ./fixtures/ca/ca.crt` 并按照提示进行操作。测试后请删除此证书！如果有解决方法，请告诉我们。

示例 2: 用HTTPS客户端证书的客户端到服务器端认证

现在我们已经给了 etcd 客户端验证服务器身份和提供传输安全性的能力。我们也可以使用客户端证书来防止对 etcd 未经授权的访问。

客户端将向服务器提供证书，服务器将检查证书是否由CA签名，并决定是否服务请求。

为此需要第一个示例中提到的相同文件，以及由同一证书颁发机构签名的客户端（ `client.crt` , `client.key` ）密钥对。

```
$ etcd --name infra0 --data-dir infra0 \
  --client-cert-auth --trusted-ca-file=/path/to/ca.crt --cert-file=/path/to/server.crt
  --key-file=/path/to/server.key \
  --advertise-client-urls https://127.0.0.1:2379 --listen-client-urls https://127.0.0.1:2379
```

现在尝试发送与上面相同的请求到服务器：

```
$ curl --cacert /path/to/ca.crt https://127.0.0.1:2379/v2/keys/foo -XPUT -d value=bar
-v
```

该请求会被服务器拒绝：

```
...
routines:SSL3_READ_BYTES:ssl3 alert bad certificate
...
```

要想请求成功，我们需要将CA签名的客户端证书发送给服务器：

```
$ curl --cacert /path/to/ca.crt --cert /path/to/client.crt --key /path/to/client.key \
  -L https://127.0.0.1:2379/v2/keys/foo -XPUT -d value=bar -v
```

输出为：

```
...
SSLv3, TLS handshake, CERT verify (15):
...
TLS handshake, Finished (20)
```

还有来自服务器的响应：

```
{
  "action": "set",
  "node": {
    "createdIndex": 12,
    "key": "/foo",
    "modifiedIndex": 12,
    "value": "bar"
  }
}
```

示例 3: 集群中的传输安全和客户端证书

对于对等通信，etcd 支持与上述相同的模型，这意味着集群中的 etcd 成员之间的通信。

Assuming we have our `ca.crt` and two members with their own keypairs (`member1.crt` & `member1.key` , `member2.crt` & `member2.key`) signed by this CA, we launch etcd as follows:

假设我们有我们的 `ca.crt` 和两个成员，他们有这个CA签名的自己的 keypairs (`member1.crt` & `member1.key` , `member2.crt` & `member2.key`)，我们如下启动 etcd：

```
DISCOVERY_URL=... # from https://discovery.etcd.io/new

# member1
$ etcd --name infra1 --data-dir infra1 \
  --peer-client-cert-auth --peer-trusted-ca-file=/path/to/ca.crt --peer-cert-file=/path/to/member1.crt --peer-key-file=/path/to/member1.key \
  --initial-advertise-peer-urls=https://10.0.1.10:2380 --listen-peer-urls=https://10.0.1.10:2380 \
  --discovery ${DISCOVERY_URL}

# member2
$ etcd --name infra2 --data-dir infra2 \
  --peer-client-cert-auth --peer-trusted-ca-file=/path/to/ca.crt --peer-cert-file=/path/to/member2.crt --peer-key-file=/path/to/member2.key \
  --initial-advertise-peer-urls=https://10.0.1.11:2380 --listen-peer-urls=https://10.0.1.11:2380 \
  --discovery ${DISCOVERY_URL}
```

etcd 成员将组成一个集群，集群中成员之间的所有通信将使用客户端证书进行加密和验证。etcd 的输出将显示其连接的地址使用 HTTPS。

Example 4: 自动自签名安全

对于需要通信加密而需要认证的情况，etcd 支持使用自动生成的自签名证书来加密其消息。这样可以简化部署，因为不需要管理 etcd 以外的证书和密钥。

使用标志 `--auto-tls` 和 `--peer-auto-tls` 配置 etcd 为客户端和对等连接使用自签名证书：

```
DISCOVERY_URL=... # from https://discovery.etcd.io/new

# member1
$ etcd --name infra1 --data-dir infra1 \
  --auto-tls --peer-auto-tls \
  --initial-advertise-peer-urls=https://10.0.1.10:2380 --listen-peer-urls=https://10.0.1.10:2380 \
  --discovery ${DISCOVERY_URL}

# member2
$ etcd --name infra2 --data-dir infra2 \
  --auto-tls --peer-auto-tls \
  --initial-advertise-peer-urls=https://10.0.1.11:2380 --listen-peer-urls=https://10.0.1.11:2380 \
  --discovery ${DISCOVERY_URL}
```

自签名证书不会对身份进行验证，因此 `curl` 将返回错误：

```
curl: (60) SSL certificate problem: Invalid certificate chain
```

要禁用证书链检查，请使用 `-k` 标志调用 `curl`：

```
$ curl -k https://127.0.0.1:2379/v2/keys/foo -Xput -d value=bar -v
```

etcd proxy 注意事项

如果连接是安全的，`etcd proxy` 从其客户端终止 TLS，并且使用 `--peer-key-file` 和 `--peer-cert-file` 中指定的代理自己的密钥/证书与 `etcd` 成员进行通信。

`proxy` 通过给定成员的 `--advertise-client-urls` 和 `--advertise-peer-urls` 与 `etcd` 成员进行通信。它将客户端请求转发到 `etcd` 成员的 `advertised client url`，并通过 `etcd` 成员的 `advertised peer url` 同步初始集群配置。

当 `etcd` 成员启用客户端身份验证时，管理员必须确保代理的 `--peer-cert-file` 选项中指定的对等证书对于该验证是有效的。如果启用对等身份验证，`proxy` 的对等证书也必须对对等身份验证有效。

FAQ

使用 TLS 客户端身份验证时，我看到 **SSLv3** 警报握手失败？

`golang` 的 `crypto / tls` 包在使用它之前检查证书公钥的 `key usage`。

要使用证书公钥进行客户端认证，我们需要在创建证书公钥时将 `clientAuth` 添加到 `Extended Key Usage` 。

这是怎么做的：

1. 将以下部分添加到 `openssl.cnf`:

```
[ ssl_client ]
...
    extendedKeyUsage = clientAuth
...
```

2. 创建证书时，确保在 `-extensions` 标志中引用它:

```
$ openssl ca -config openssl.cnf -policy policy_anything -extensions ssl_client -
out certs/machine.crt -infiles machine.csr
```

使用对等证书认证，我收到"证书对**127.0.0.1**有效，而不是**\$MY_IP**"

确保使用成员的公共IP地址为 `Subject` 名称来签署证书。例如 `etcd-ca` 工具为它的 `new-cert` 命令提供 `--ip=` 选项。

证书需要在其 `Subject` 名称中为成员的 FQDN 签名，使用 `Subject Alternative Names`（短IP SAN）来添加IP地址。`etcd-ca` 工具为它的 `new-cert` 命令提供 `--domain=` 选项，而且 `openssl` 也可以[这样实现](#)。

Role-based access control

Overview

Authentication was added in etcd 2.1. The etcd v3 API slightly modified the authentication feature's API and user interface to better fit the new data model. This guide is intended to help users set up basic authentication and role-based access control in etcd v3.

Special users and roles

There is one special user, `root`, and one special role, `root`.

User `root`

The `root` user, which has full access to etcd, must be created before activating authentication. The idea behind the `root` user is for administrative purposes: managing roles and ordinary users. The `root` user must have the `root` role and is allowed to change anything inside etcd.

Role `root`

The role `root` may be granted to any user, in addition to the root user. A user with the `root` role has both global read-write access and permission to update the cluster's authentication configuration. Furthermore, the `root` role grants privileges for general cluster maintenance, including modifying cluster membership, defragmenting the store, and taking snapshots.

Working with users

The `user` subcommand for `etcdctl` handles all things having to do with user accounts.

A listing of users can be found with:

```
$ etcdctl user list
```

Creating a user is as easy as

```
$ etcdctl user add myusername
```

Creating a new user will prompt for a new password. The password can be supplied from standard input when an option `--interactive=false` is given.

Roles can be granted and revoked for a user with:

```
$ etcdctl user grant-role myusername foo
$ etcdctl user revoke-role myusername bar
```

The user's settings can be inspected with:

```
$ etcdctl user get myusername
```

And the password for a user can be changed with

```
$ etcdctl user passwd myusername
```

Changing the password will prompt again for a new password. The password can be supplied from standard input when an option `--interactive=false` is given.

Delete an account with:

```
$ etcdctl user delete myusername
```

Working with roles

The `role` subcommand for `etcdctl` handles all things having to do with access controls for particular roles, as were granted to individual users.

List roles with:

```
$ etcdctl role list
```

Create a new role with:

```
$ etcdctl role add myrolename
```

A role has no password; it merely defines a new set of access rights.

Roles are granted access to a single key or a range of keys.

The range can be specified as an interval [start-key, end-key) where start-key should be lexically less than end-key in an alphabetical manner.

Access can be granted as either read, write, or both, as in the following examples:

```
# Give read access to a key /foo
$ etcdctl role grant-permission myrolename read /foo

# Give read access to keys with a prefix /foo/. The prefix is equal to the range [/foo
/, /foo0)
$ etcdctl role grant-permission myrolename --prefix=true read /foo/

# Give write-only access to the key at /foo/bar
$ etcdctl role grant-permission myrolename write /foo/bar

# Give full access to keys in a range of [key1, key5)
$ etcdctl role grant-permission myrolename readwrite key1 key5

# Give full access to keys with a prefix /pub/
$ etcdctl role grant-permission myrolename --prefix=true readwrite /pub/
```

To see what's granted, we can look at the role at any time:

```
$ etcdctl role get myrolename
```

Revocation of permissions is done the same logical way:

```
$ etcdctl role revoke-permission myrolename /foo/bar
```

As is removing a role entirely:

```
$ etcdctl role remove myrolename
```

Enabling authentication

The minimal steps to enabling auth are as follows. The administrator can set up users and roles before or after enabling authentication, as a matter of preference.

Make sure the root user is created:

```
$ etcdctl user add root
Password of root:
```

Enable authentication:

```
$ etcdctl auth enable
```

After this, etcd is running with authentication enabled. To disable it for any reason, use the reciprocal command:

```
$ etcdctl --user root:rootpw auth disable
```

Using `etcdctl` to authenticate

`etcdctl` supports a similar flag as `curl` for authentication.

```
$ etcdctl --user user:password get foo
```

The password can be taken from a prompt:

```
$ etcdctl --user user get foo
```

Otherwise, all `etcdctl` commands remain the same. Users and roles can still be created and modified, but require authentication by a user with the root role.

Using TLS Common Name

If an etcd server is launched with the option `--client-cert-auth=true`, the field of Common Name (CN) in the client's TLS cert will be used as an etcd user. In this case, the common name authenticates the user and the client does not need a password.

Frequently Asked Questions (FAQ)

etcd, general

Do clients have to send requests to the etcd leader?

[Raft](#) is leader-based; the leader handles all client requests which need cluster consensus. However, the client does not need to know which node is the leader. Any request that requires consensus sent to a follower is automatically forwarded to the leader. Requests that do not require consensus (e.g., serialized reads) can be processed by any cluster member.

Configuration

What is the difference between advertise-urls and listen-urls?

`listen-urls` specifies the local addresses etcd server binds to for accepting incoming connections. To listen on a port for all interfaces, specify `0.0.0.0` as the listen IP address.

`advertise-urls` specifies the addresses etcd clients or other etcd members should use to contact the etcd server. The advertise addresses must be reachable from the remote machines. Do not advertise addresses like `localhost` or `0.0.0.0` for a production setup since these addresses are unreachable from remote machines.

Deployment

System requirements

Since etcd writes data to disk, SSD is highly recommended. To prevent performance degradation or unintentionally overloading the key-value store, etcd enforces a 2GB default storage size quota, configurable up to 8GB. To avoid swapping or running out of memory, the machine should have at least as much RAM to cover the quota. At CoreOS, an etcd cluster is usually deployed on dedicated CoreOS Container Linux machines with dual-core processors, 2GB of RAM, and 80GB of SSD *at the very least*. **Note that performance is intrinsically workload dependent; please test before production deployment.** See [hardware](#) for more recommendations.

Most stable production environment is Linux operating system with amd64 architecture; see [supported platform](#) for more.

Why an odd number of cluster members?

An etcd cluster needs a majority of nodes, a quorum, to agree on updates to the cluster state. For a cluster with n members, quorum is $(n/2)+1$. For any odd-sized cluster, adding one node will always increase the number of nodes necessary for quorum. Although adding a node to an odd-sized cluster appears better since there are more machines, the fault tolerance is worse since exactly the same number of nodes may fail without losing quorum but there are more nodes that can fail. If the cluster is in a state where it can't tolerate any more failures, adding a node before removing nodes is dangerous because if the new node fails to register with the cluster (e.g., the address is misconfigured), quorum will be permanently lost.

What is maximum cluster size?

Theoretically, there is no hard limit. However, an etcd cluster probably should have no more than seven nodes. [Google Chubby lock service](#), similar to etcd and widely deployed within Google for many years, suggests running five nodes. A 5-member etcd cluster can tolerate two member failures, which is enough in most cases. Although larger clusters provide better fault tolerance, the write performance suffers because data must be replicated across more machines.

What is failure tolerance?

An etcd cluster operates so long as a member quorum can be established. If quorum is lost through transient network failures (e.g., partitions), etcd automatically and safely resumes once the network recovers and restores quorum; Raft enforces cluster consistency. For power loss, etcd persists the Raft log to disk; etcd replays the log to the point of failure and resumes cluster participation. For permanent hardware failure, the node may be removed from the cluster through [runtime reconfiguration](#).

It is recommended to have an odd number of members in a cluster. An odd-size cluster tolerates the same number of failures as an even-size cluster but with fewer nodes. The difference can be seen by comparing even and odd sized clusters:

Cluster Size	Majority	Failure Tolerance
1	1	0
2	2	0
3	2	1
4	3	1
5	3	2
6	4	2
7	4	3
8	5	3
9	5	4

Adding a member to bring the size of cluster up to an even number doesn't buy additional fault tolerance. Likewise, during a network partition, an odd number of members guarantees that there will always be a majority partition that can continue to operate and be the source of truth when the partition ends.

Does etcd work in cross-region or cross data center deployments?

Deploying etcd across regions improves etcd's fault tolerance since members are in separate failure domains. The cost is higher consensus request latency from crossing data center boundaries. Since etcd relies on a member quorum for consensus, the latency from crossing data centers will be somewhat pronounced because at least a majority of cluster members must respond to consensus requests. Additionally, cluster data must be replicated across all peers, so there will be bandwidth cost as well.

With longer latencies, the default etcd configuration may cause frequent elections or heartbeat timeouts. See [tuning](#) for adjusting timeouts for high latency deployments.

Operation

How to backup a etcd cluster?

etcdctl provides a `snapshot` command to create backups. See [backup](#) for more details.

Should I add a member before removing an unhealthy member?

When replacing an etcd node, it's important to remove the member first and then add its replacement.

etcd employs distributed consensus based on a quorum model; $(n+1)/2$ members, a majority, must agree on a proposal before it can be committed to the cluster. These proposals include key-value updates and membership changes. This model totally avoids any possibility of split brain inconsistency. The downside is permanent quorum loss is catastrophic.

How this applies to membership: If a 3-member cluster has 1 downed member, it can still make forward progress because the quorum is 2 and 2 members are still live. However, adding a new member to a 3-member cluster will increase the quorum to 3 because 3 votes are required for a majority of 4 members. Since the quorum increased, this extra member buys nothing in terms of fault tolerance; the cluster is still one node failure away from being unrecoverable.

Additionally, that new member is risky because it may turn out to be misconfigured or incapable of joining the cluster. In that case, there's no way to recover quorum because the cluster has two members down and two members up, but needs three votes to change membership to undo the botched membership addition. etcd will by default reject member add attempts that could take down the cluster in this manner.

On the other hand, if the downed member is removed from cluster membership first, the number of members becomes 2 and the quorum remains at 2. Following that removal by adding a new member will also keep the quorum steady at 2. So, even if the new node can't be brought up, it's still possible to remove the new member through quorum on the remaining live members.

Why won't etcd accept my membership changes?

etcd sets `strict-reconfig-check` in order to reject reconfiguration requests that would cause quorum loss. Abandoning quorum is really risky (especially when the cluster is already unhealthy). Although it may be tempting to disable quorum checking if there's quorum loss to add a new member, this could lead to full fledged cluster inconsistency. For many applications, this will make the problem even worse ("disk geometry corruption" being a candidate for most terrifying).

Performance

How should I benchmark etcd?

Try the [benchmark](#) tool. Current [benchmark results](#) are available for comparison.

What does the etcd warning "apply entries took too long" mean?

After a majority of etcd members agree to commit a request, each etcd server applies the request to its data store and persists the result to disk. Even with a slow mechanical disk or a virtualized network disk, such as Amazon's EBS or Google's PD, applying a request should normally take fewer than 50 milliseconds. If the average apply duration exceeds 100 milliseconds, etcd will warn that entries are taking too long to apply.

Usually this issue is caused by a slow disk. The disk could be experiencing contention among etcd and other applications, or the disk is too simply slow (e.g., a shared virtualized disk). To rule out a slow disk from causing this warning, monitor [backend_commit_duration_seconds](#) (p99 duration should be less than 25ms) to confirm the disk is reasonably fast. If the disk is too slow, assigning a dedicated disk to etcd or using faster disk will typically solve the problem.

The second most common cause is CPU starvation. If monitoring of the machine's CPU usage shows heavy utilization, there may not be enough compute capacity for etcd. Moving etcd to dedicated machine, increasing process resource isolation cgroups, or renicing the etcd server process into a higher priority can usually solve the problem.

Expensive user requests which access too many keys (e.g., fetching the entire keyspace) can also cause long apply latencies. Accessing fewer than a several hundred keys per request, however, should always be performant.

If none of the above suggestions clear the warnings, please [open an issue](#) with detailed logging, monitoring, metrics and optionally workload information.

What does the etcd warning "failed to send out heartbeat on time" mean?

etcd uses a leader-based consensus protocol for consistent data replication and log execution. Cluster members elect a single leader, all other members become followers. The elected leader must periodically send heartbeats to its followers to maintain its leadership. Followers infer leader failure if no heartbeats are received within an election interval and trigger an election. If a leader doesn't send its heartbeats in time but is still running, the election is spurious and likely caused by insufficient resources. To catch these soft failures, if the leader skips two heartbeat intervals, etcd will warn it failed to send a heartbeat on time.

Usually this issue is caused by a slow disk. Before the leader sends heartbeats attached with metadata, it may need to persist the metadata to disk. The disk could be experiencing contention among etcd and other applications, or the disk is too simply slow (e.g., a shared virtualized disk). To rule out a slow disk from causing this warning, monitor

`wal_fsync_duration_seconds` (p99 duration should be less than 10ms) to confirm the disk is reasonably fast. If the disk is too slow, assigning a dedicated disk to etcd or using faster disk will typically solve the problem.

The second most common cause is CPU starvation. If monitoring of the machine's CPU usage shows heavy utilization, there may not be enough compute capacity for etcd. Moving etcd to dedicated machine, increasing process resource isolation with cgroups, or renicing the etcd server process into a higher priority can usually solve the problem.

A slow network can also cause this issue. If network metrics among the etcd machines shows long latencies or high drop rate, there may not be enough network capacity for etcd. Moving etcd members to a less congested network will typically solve the problem. However, if the etcd cluster is deployed across data centers, long latency between members is expected. For such deployments, tune the `heartbeat-interval` configuration to roughly match the round trip time between the machines, and the `election-timeout` configuration to be at least $5 * \text{heartbeat-interval}$. See [tuning documentation](#) for detailed information.

If none of the above suggestions clear the warnings, please [open an issue](#) with detailed logging, monitoring, metrics and optionally workload information.

What does the etcd warning "request ignored (cluster ID mismatch)" mean?

Every new etcd cluster generates a new cluster ID based on the initial cluster configuration and a user-provided unique `initial-cluster-token` value. By having unique cluster ID's, etcd is protected from cross-cluster interaction which could corrupt the cluster.

Usually this warning happens after tearing down an old cluster, then reusing some of the peer addresses for the new cluster. If any etcd process from the old cluster is still running it will try to contact the new cluster. The new cluster will recognize a cluster ID mismatch, then ignore the request and emit this warning. This warning is often cleared by ensuring peer addresses among distinct clusters are disjoint.

Monitoring etcd

Each etcd server exports metrics under the `/metrics` path on its client port.

The metrics can be fetched with `curl` :

```
$ curl -L http://localhost:2379/metrics

# HELP etcd_debugging_mvcc_keys_total Total number of keys.
# TYPE etcd_debugging_mvcc_keys_total gauge
etcd_debugging_mvcc_keys_total 0
# HELP etcd_debugging_mvcc_pending_events_total Total number of pending events to be sent.
# TYPE etcd_debugging_mvcc_pending_events_total gauge
etcd_debugging_mvcc_pending_events_total 0
...
```

Prometheus

Running a [Prometheus](#) monitoring service is the easiest way to ingest and record etcd's metrics.

First, install Prometheus:

```
PROMETHEUS_VERSION="1.3.1"
wget https://github.com/prometheus/prometheus/releases/download/v$PROMETHEUS_VERSION/prometheus-$PROMETHEUS_VERSION.linux-amd64.tar.gz -O /tmp/prometheus-$PROMETHEUS_VERSION.linux-amd64.tar.gz
tar -xvzf /tmp/prometheus-$PROMETHEUS_VERSION.linux-amd64.tar.gz --directory /tmp/ --strip-components=1
/tmp/prometheus -version
```

Set Prometheus's scraper to target the etcd cluster endpoints:

```
cat > /tmp/test-etcd.yaml <<EOF
global:
  scrape_interval: 10s
scrape_configs:
  - job_name: test-etcd
    static_configs:
      - targets: ['10.240.0.32:2379', '10.240.0.33:2379', '10.240.0.34:2379']
EOF
cat /tmp/test-etcd.yaml
```

Set up the Prometheus handler:

```
nohup /tmp/prometheus \
  -config.file /tmp/test-etcd.yaml \
  -web.listen-address ":9090" \
  -storage.local.path "test-etcd.data" >> /tmp/test-etcd.log 2>&1 &
```

Now Prometheus will scrape etcd metrics every 10 seconds.

Grafana

[Grafana](#) has built-in Prometheus support; just add a Prometheus data source:

```
Name:    test-etcd
Type:    Prometheus
Url:     http://localhost:9090
Access:  proxy
```

Then import the default [etcd dashboard template](#) and customize. For instance, if Prometheus data source name is `my-etcd`, the `datasource` field values in JSON also need to be `my-etcd`.

See the [demo](#).

Sample dashboard:



维护

概述

etcd 集群需要定期维护来保持可靠。基于 etcd 应用的需要，这个维护通常可以自动执行，不需要停机或者显著的降低性能。

所有 etcd 的维护是指管理被 etcd 键空间消耗的存储资源。通过存储空间的配额来控制键空间大小;如果 etcd 成员运行空间不足，将触发集群级警告，这将使得系统进入有限操作的维护模式。为了避免没有空间来写入键空间，etcd 键空间历史必须被压缩。存储空间自身可能通过碎片整理 etcd 成员来回收。最后，etcd 成员状态的定期快照备份使得恢复任何非故意的逻辑数据丢失或者操作错误导致的损坏变成可能。

历史压缩

因为 etcd 保持它的键空间的确切历史，这个历史应该定期压缩来避免性能下降和最终的存储空间枯竭。压缩键空间历史删除所有关于被废弃的在给定键空间修订版本之前的键的信息。这些key使用的空间随机变得可用来继续写入键空间。

键空间可以使用 `etcd` 的时间窗口历史保持策略自动压缩，或者使用 `etcdctl` 手工压缩。`etcdctl` 方法在压缩过程上提供细粒度的控制，反之自动压缩适合仅仅需要一定时间长度的键历史的应用。

`etcd` 可以使用带有小时时间单位的 `--auto-compaction` 选项来设置为自动压缩键空间:

```
# 保持一个小时的历史
$ etcd --auto-compaction-retention=1
```

`etcdctl` 如下发起压缩工作:

```
# 压缩到修订版本3
$ etcdctl compact 3
```

在压缩修订版本之前的修订版本变得无法访问:

```
$ etcdctl get --rev=2 somekey
Error: rpc error: code = 11 desc = etcdserver: mvcc: required revision has been compacted
```

反碎片化

在压缩键空间之后，后端数据库可能出现内部。内部碎片是指可以被后端使用但是依然消耗存储空间的空间。反碎片化过程释放这个存储空间到文件系统。反碎片化在每个成员上发起，因此集群范围的延迟尖峰(latency spike)可能可以避免。

通过留下间隔在后端数据库，压缩旧有修订版本会内部碎片化 `etcd`。碎片化的空间可以被 `etcd` 使用，但是对于主机文件系统不可用。

为了反碎片化 `etcd` 成员，使用 `etcdctl defrag` 命令:

```
$ etcdctl defrag
Finished defragmenting etcd member[127.0.0.1:2379]
```

空间配额

在 `etcd` 中空间配额确保集群以可靠方式运作。没有空间配额，`etcd` 可能会收到低性能的困扰，如果键空间增长的过度的巨大，或者可能简单的超过存储空间，导致不可预测的集群行为。如果键空间的任何成员的后端数据库超过了空间配额，`etcd` 发起集群范围的警告，让集群进入维护模式，仅接收键的读取和删除。在键空间释放足够的空间之后，警告可以被解除，而集群将恢复正常运作。

默认，`etcd` 设置适合大多数应用的保守的空间配额，但是它可以在命令行中设置，单位为字节：

```
# 设置非常小的 16MB 配额
$ etcd --quota-backend-bytes=16777216
```

空间配额可以用循环触发：

```
# 消耗空间
$ while [ 1 ]; do dd if=/dev/urandom bs=1024 count=1024 | etcdctl put key || break;
done
...
Error: rpc error: code = 8 desc = etcdserver: mvcc: database space exceeded
# 确认配额空间被超过
$ etcdctl --write-out=table endpoint status
+-----+-----+-----+-----+-----+-----+-----+
|      ENDPOINT      |      ID      |  VERSION  | DB SIZE | IS LEADER | RAFT TERM | RA
FT INDEX |
+-----+-----+-----+-----+-----+-----+-----+
| 127.0.0.1:2379 | bf9071f4639c75cc | 2.3.0+git | 18 MB   | true      | 2         | 6
3352 |
+-----+-----+-----+-----+-----+-----+-----+
# 确认警告已发起
$ etcdctl alarm list
memberID:13803658152347727308 alarm:NOSPACE
```

删除多读的键空间将把集群带回配额限制，因此警告能被接触：

```
# 获取当前修订版本
$ etcdctl --endpoints=:2379 endpoint status
[{"Endpoint": "127.0.0.1:2379", "Status": {"header": {"cluster_id": 8925027824743593106, "member_id": 13803658152347727308, "revision": 1516, "raft_term": 2}, "version": "2.3.0+git", "db Size": 17973248, "leader": 13803658152347727308, "raftIndex": 6359, "raftTerm": 2}}]
# 压缩所有旧有修订版本
$ etcdctl compact 1516
compactd revision 1516
# 反碎片化过度空间
$ etcdctl defrag
Finished defragmenting etcd member[127.0.0.1:2379]
# 解除警告
$ etcdctl alarm disarm
memberID:13803658152347727308 alarm:NOSPACE
# 测试put被再度容许
$ etcdctl put newkey 123
OK
```

快照备份

在正规基础上执行 `etcd` 集群快照可以作为 `etcd` 键空间的持久备份。通过获取 `etcd` 成员的候选数据库的定期快照，`etcd` 集群可以被恢复到某个有已知良好状态的时间点。

通过 `etcdctl` 获取快照：

```
$ etcdctl snapshot save backup.db
$ etcdctl --write-out=table snapshot status backup.db
+-----+-----+-----+-----+
|  HASH   | REVISION | TOTAL KEYS | TOTAL SIZE |
+-----+-----+-----+-----+
| fe01cf57 |      10 |          7 | 2.1 MB     |
+-----+-----+-----+-----+
```


理解失败

在机器的大量部署中失败是很常见的。当硬件或者软件故障时单台机器失败。当电力故障或者网络问题时多台机器一起失败。多种失败也可能一起发生;几乎不可能列举出所有可能的失败场景。

在这节中，我们分类失败的种类并讨论 `etcd` 是如何设计来容忍这些失败的。大部分用户，不是所有，可以映射一个特别的失败到一种失败。为了应对罕见或者 [不可恢复的失败](#)，总是 [备份 etcd 集群](#)。

少数跟随者失败

当少于一半的跟随者失败时，`etcd` 集群依然可以接收请求并让程序没有任何大的中断。例如，两个跟随者失败将不会影响一个五个成员的 `etcd` 集群运作。但是，客户端将失去到失败成员的连通性。对于读请求客户端类库应该通过自动重新连接到其他成员来对用户隐藏这些中断。运维人员应该预期其他成员上的系统负载会因为重新连接而提升。

Leader 失败

当 `leader` 失败时，`etcd` 集群自动选举一个新的 `leader`。选举不会在 `leader` 失败之后立即发生。大约需要一个选举超时的时间来选举新的 `leader`，因为失败选取模型是基于超时的。

在 `leader` 选举的期间，集群不能处理任何写。在选举期间发送的写请求将排队等待处理知道新的 `leader` 被选举出来。

已经发送给旧有 `leader` 但是还没有提交的写请求可能会丢失。新的 `leader` 有能力重新写入从之前 `leader` 而来的任何未提交的条目。从用户的角度，在新的 `leader` 选举之后某些写请求可能超时。无论如何，已提交的请求从来不会丢失。

新的 `leader` 自动延长所有的租约(`lease`)。这个机制保证足浴将不会在准许的 `TTL` 之前过期，即使它被旧有的 `leader` 准许。

多数失败

当集群的大多数成员失败时，`etcd` 集群失败并无法接收更多写请求。

`etcd` 集群仅在成员的大多数可用时可以从多数失败中恢复。如果成员的大多数无法回来上线，那么运维必须启动[disaster recovery/灾难恢复](#)来恢复集群。

一旦成员的大多数可以工作，etcd 集群自动选举新的 leader 并返回到健康状态。新的 leader 自动延长是所有租约的超时时间。这个机器确保没有租约因为服务器端不可访问而过期。

网络分区

网络分区类似少数跟随者失败或者 leader 失败。网络分区将 etcd 集群分成两个部分; 一个有大多数成员而另外一个有少数成员。多数这边变成可用集群而少数这边不可用。在 etcd 中没有"脑裂"。

如果 leader 在多数这边，那么从多数这边的角度看失败是一个少数跟随者失败。如果 leader 在少数这边，那么它是 leader 失败。在少数这边的 leader 辞职(step down)然后多数那边选举新的 leader。

一旦网络分区清除，少数这边自动承认来自多数这边的 leader 并恢复状态。

启动期间失败

集群启动时仅仅当所有要求的成员都成功启动才视为成功。如果在启动期间发生任何失败，在所有成员上删除数据目录并用新的集群记号(cluster-token)或者新的发现记号(discovery token)重新启动集群。

当然，可以像恢复运行中的集群那样恢复失败的启动集群。但是，它大多数情况下总是比启动一个新的花费更多时间和资源来恢复集群，因为没有任何数据要恢复。

灾难恢复

etcd 被设计为能承受机器失败。etcd 集群自动从临时失败(例如, 机器重启)中恢复, 而且对于一个有 N 个成员的集群能容许 $(N-1)/2$ 的持续失败。当一个成员持续失败时, 不管是因为硬件失败或者磁盘损坏, 它丢失到集群的访问。如果集群持续丢失超过 $(N-1)/2$ 的成员, 则它只能悲惨的失败, 无可救药的失去法定人数(quorum)。一旦法定人数丢失, 集群无法达到一致而因此无法继续接收更新。

为了从灾难失败中恢复, etcd v3 提供快照和修复工具来重建集群而不丢失 v3 键数据。要恢复 v2 的键, 参考[v2 管理指南](#)。

快照键空间

恢复集群首先需要来自 etcd 成员的键空间的快照。快速可以用 `etcdctl snapshot save` 命令从活动成员获取, 或者是从 etcd 数据目录复制 `member/snap/db` 文件。例如, 下列命令快照在 `$ENDPOINT` 上服务的键空间到文件 `snapshot.db` :

```
$ etcdctl --endpoints $ENDPOINT snapshot save snapshot.db
```

恢复集群

为了恢复集群, 需要的只是一个简单的快照 "db" 文件。使用 `etcdctl snapshot restore` 的集群恢复创建新的 etcd 数据目录; 所有成员应该使用相同的快照恢复。恢复覆盖某些快照元数据(特别是, 成员ID和集群ID); 成员丢失它之前的标识。这个元数据覆盖防止新的成员不经意间加入已有的集群。因此为了从快照启动集群, 恢复必须启动一个新的逻辑集群。

在恢复时快照完整性的检验是可选的。如果快照是通过 `etcdctl snapshot save` 得到的, 它将有一个被 `etcdctl snapshot restore` 检查过的完整性hash。如果快照是从数据目录复制而来, 没有完整性hash, 因此它只能通过使用 `--skip-hash-check` 来恢复。

恢复初始化新集群的新成员, 带有新的集群配置, 使用 etcd 的集群配置标记, 但是保存 etcd 键空间的内容。继续上面的例子, 下面为一个3成员的集群创建新的 etcd 数据目录 (`m1.etcd` , `m2.etcd` , `m3.etcd`):

```
$ etcdctl snapshot restore snapshot.db \  
  --name m1 \  
  --initial-cluster m1=http://host1:2380,m2=http://host2:2380,m3=http://host3:2380 \  
  --initial-cluster-token etcd-cluster-1 \  
  --initial-advertise-peer-urls http://host1:2380  
$ etcdctl snapshot restore snapshot.db \  
  --name m2 \  
  --initial-cluster m1=http://host1:2380,m2=http://host2:2380,m3=http://host3:2380 \  
  --initial-cluster-token etcd-cluster-1 \  
  --initial-advertise-peer-urls http://host2:2380  
$ etcdctl snapshot restore snapshot.db \  
  --name m3 \  
  --initial-cluster m1=http://host1:2380,m2=http://host2:2380,m3=http://host3:2380 \  
  --initial-cluster-token etcd-cluster-1 \  
  --initial-advertise-peer-urls http://host3:2380
```

下一步, 用新的数据目录启动 `etcd` :

```
$ etcd \  
  --name m1 \  
  --listen-client-urls http://host1:2379 \  
  --advertise-client-urls http://host1:2379 \  
  --listen-peer-urls http://host1:2380 &  
$ etcd \  
  --name m2 \  
  --listen-client-urls http://host2:2379 \  
  --advertise-client-urls http://host2:2379 \  
  --listen-peer-urls http://host2:2380 &  
$ etcd \  
  --name m3 \  
  --listen-client-urls http://host3:2379 \  
  --advertise-client-urls http://host3:2379 \  
  --listen-peer-urls http://host3:2380 &
```

现在恢复的集群可以使用并提供来自快照的键空间服务.

版本

服务版本

etcd 使用 [semantic versioning](#)。新的小版本可能增加额外功能到API。

使用 `etcdctl` 获取运行中的 etcd 集群的版本：

```
ETCDCTL_API=3 etcdctl --endpoints=127.0.0.1:2379 endpoint status
```

API 版本

在 3.0.0 发布值偶 `v3` API 应答将不会更改，但是随着时间的推移将加入新的功能。

学习

内容

- 什么是etcd?
- 理解数据模型
- 理解API
- 术语
- API保证
- Internals (TODO)

额外说明

1. 这些内容主要是介绍 etcd 的概念和实现细节，适合希望深入了解 etcd 的同学。
2. 内容来自 github 官网，地址：
<https://github.com/coreos/etcd/tree/master/Documentation/learning>

为什么是etcd?

"etcd"这个名字源于两个想法，即 `unix "/etc"` 文件夹和分布式系统"`distributed`"。"`/etc`" 文件夹为单个系统存储配置数据的地方，而 `etcd` 存储大规模分布式系统的配置信息。因此，"`distributed`" 的 "`/etc`"，是为 "`etcd`"。

`etcd` 以一致和容错的方式存储元数据。分布式系统使用 `etcd` 作为一致性键值存储，用于配置管理，服务发现和协调分布式工作。使用 `etcd` 的通用分布式模式包括领导选举，[分布式锁](#)和监控机器活动。

使用案例

- **CoreOS 的容器 Linux:** 在[Container Linux](#)上运行的应用程序获得自动的不宕机 Linux 内核更新。容器 Linux 使用[locksmith](#)来协调更新。`locksmith` 在 `etcd` 上实现分布式信号量，确保在任何给定时间只有集群的一个子集重新启动。
- **Kubernetes** 将配置数据存储到`etcd`中，用于服务发现和集群管理; `etcd` 的一致性对于正确安排和运行服务至关重要。`Kubernetes API` 服务器将群集状态持久化在 `etcd` 中。它使用`etcd`的 `watch API`监视集群，并发布关键的配置更改。

功能和系统比较

TODO

数据模型

etcd 设计用于可靠存储不频繁更新的数据，并提供可靠的观察查询。etcd 暴露键值对的先前版本来支持不昂贵的快速和观察历史事件("time travel queries")。对于这些使用场景，持久化，多版本，并发控制的数据模型是非常适合的。

etcd 使用多版本持久化键值存储来存储数据。当键值对的值被新的数据替代时，持久化键值存储保存先前版本的键值对。键值存储事实上是不可变的;它的操作不会就地更新结构，替代的是总是生成一个新的更新后的结构。在修改之后，key的所有先前版本还是可以访问和观察的。为了防止随着时间的过去为了维护老版本导致数据存储无限增长，存储应该压缩来脱离被替代的数据的最旧的版本。

逻辑视图

存储的逻辑视图是一个扁平的二进制键空间。键空间有一个在 byte string 键上的语义排序的索引，因此范围查询不是太昂贵。

键空间维护多个版本。每个原子变化操作(类如，一个事务操作可能包含多个操作)在键空间上创建一个新的修订版本。先前版本持有的所有数据保持不变。key 的旧有版本还可以通过先前修订版本访问。同样的，修订版本也是被索引的;在修订版本上搜索(带观察者)是高效的。一旦存储被压缩来恢复空间，在压缩修订版本之前的修订版本被移除。

key的生命周期跨越一代(spans a generation)。每个 key 可以有一代或者多代。创建 key 增加了 key 的代，如果 key 从未存在则从 1 开始。删除一个 key 产生一个 key 的墓碑，结束 key 的当前时代。key 的每次改动创建 key 的一个新的版本。一旦压缩发生，任何在给定修订版本之前结束的时代将被删除，而在压缩修订版本之前设置的值，除最后一个外，都将被移除。

物理视图

etcd 以持久性 b+tree 键值对的方式存储物理数据。存储的状态的每个修订版本仅仅包含和它的前一个修订版本的增量以求高效。单个修订版本可能对应到 tree 上的多个 key。

键值对的 key 是三元数组(major, sub, type)。Major 是持有 key 的存储修订版本。Sub 区分同一个修订版本的不同key。Type是用于特别值(例如，t，如果值包含一个墓碑)的可选后缀。键值对的值包含对前一个修订版本的改动，例如对前一个修订版本的增量。b+tree 以 key 的词典字节顺序排序。在修订版本增量上的延伸查找(Ranged lookups)很快。这样可以快速发送从一个特定修订版本到另一个的改变。压缩删除过期的键值对。

etcd 也保持内存中的第二 btree 索引来加速 key 的范围查询。在 btree 索引中的 key 是存储暴露给用户的 key。值是到持久化 b+tree 修改的指针。压缩删除死指针。

etcd3 API

注意: 这个文档还没有完成!

注：原文如此，的确是还没有完成 :)

Response header

从etcd API返回的所有应答都附带有 **response header**。这个response header包含应答的元数据。

```
message ResponseHeader {
  uint64 cluster_id = 1;
  uint64 member_id = 2;
  int64 revision = 3;
  uint64 raft_term = 4;
}
```

- Cluster_ID - 生成应答的集群的ID
- Member_ID - 生成应答的成员的ID
- Revision - 当应答生成时键值存储的修订版本
- Raft_Term - 当应答生成时成员的 Raft term

应用可以读取 Cluster_ID (Member_ID) 字段来确保它正在和预期的集群(成员)通讯。

应用可以使用 Revision/修订版本 来获知键值存储最新的修订版本。当应用指定一个历史修订版本来实现 time travel query 并希望知道请求时刻最新的修订版本时有用。

应用可以使用 Raft_Term 来检测集群何时完成了新的leader选举。

键值 API

键值API用于操作etcd中的键值对存储。键值API被定义为 **gRPC服务**。在 **protobuf 格式**中键值对被定义为结构化的数据。

键值对

键值对是键值API可以操作的最小单元。每个键值对有一些字段：

```
message KeyValue {  
    bytes key = 1;  
    int64 create_revision = 2;  
    int64 mod_revision = 3;  
    int64 version = 4;  
    bytes value = 5;  
    int64 lease = 6;  
}
```

- **Key** - 字节数组形式的key。key不容许空。
- **Value** - 字节数组形式的value
- **Version** - key的版本。删除将重置版本为0而key的任何修改将增加它的版本。
- **Create_Revision** - key最后一次创建的修订版本。
- **Mod_Revision** - key最后一次修改的修订版本。
- **Lease** - 附加到key的租约的ID。如果lease为0,则表示没有租约附加到key。

术语

这份文档定义etcd文档，命令行和源代码中使用的多个术语。

Node / 节点

Node/节点 是 raft 状态机的一个实例。

它有唯一标识，并内部记录其他节点的发展，如果它是leader。

Member / 成员

Member/成员是 etcd 的一个实例。它承载一个 node/节点，并为client/客户端提供服务。

Cluster / 集群

Cluster/集群由多个 member/成员组成。

每个成员的节点遵循 raft 一致性协议来复制日志。集群从成员中接收提案，提交他们并应用到本地存储。

Peer / 同伴

Peer/同伴是同一个集群中的其他成员。

Proposal / 提议

提议是一个需要完成 raft 协议的请求(例如写请求，配置修改请求)。

Client / 客户端

Client/客户端是集群 HTTP API的调用者。

注：对于V3,应该包括 gRPC API。

Machine / 机器 (弃用)

在 2.0 版本之前，在 `etcd` 中的成员备选。

KV API 保证

etcd 是一致而持久的键值存储，带有微事务(mini-transaction)。键值对存储通过 KV API 暴露。etcd 力图为分布式系统获取最强的一致性和持久性保证。这份规范列举 etcd 实现的 KV API 保证。

考虑的 APIs

- 读 APIs
 - range
 - watch
- 写 APIs
 - put
 - delete
- 联合 (读-改-写) APIs
 - txn

etcd 明确定义

操作完成

当 etcd 操作通过一致同意而提交时，视为操作完成，并且因此"执行过" -- 永久保存 -- 被 etcd 存储引擎。当客户端从 etcd 服务器接收到应答时，客户端得知操作已经完成。注意，如果客户端和 etcd 成员之间有超时或者网络中断，客户端可能不确定操作的状态。当有 leader 选举时，etcd 也可能中止操作。在这个事件中，etcd 不会发送 `abort` 应答给客户端的未完成的请求。

revision/修订版本

修改键值存储的 etcd 操作被分配有一个唯一的增加的修订版本。事务操作可能多次修改键值存储，但是只分配一个修订版本。被操作修改的键值对的 revision 属性和操作的 revision 有同样的值。修订版本可以用来给键值存储做逻辑时间。有较大修订版本的键值对在有较小修订版本的键值对之后修改。两个拥有相同修订版本的键值对是被一个操作同时修改。

提供的保证

原子性

所有 API 请求都是原子的; 操作或者完整的完成, 或者完全不。对于观察请求, 一个操作生成的所有事件将在一个观察应答中。观察绝不会看到一个操作的部分事件。

一致性

所有 API 调用确保 **顺序一致性**, 分布式系统可用的最强的一致性保证。不管客户端的请求发往哪个 etcd 成员, 客户端以同样的顺序读取相同的事件。如果两个成员完成同样数量的操作, 这两个成员的状态是一致的。

对于观察操作, etcd 保证所有成员对于同样的修订版本返回同样的 key 返回同样的值。对于范围操作, etcd 有类似的线性一致性访问保证; 连续访问可能落后于法定人数状态 (quorum state), 因此后来的修订版本还不用。

这段好晦涩, 原文: For range operations, etcd has a similar guarantee for linearized access; serialized access may be behind the quorum state, so that the later revision is not yet available.

和所有分布式系统一样, 对 etcd 来说确保强一致性是不可能的。etcd 不保证它会给读操作返回在任意集群成员上可以访问的“最近”(most recent)的值

等待 review, 翻译不好, 原文: etcd does not guarantee that it will return to a read the “most recent” value (as measured by a wall clock when a request is completed) available on any cluster member.

隔离

etcd 确保串行化隔离, 这是在分布式系统中可用的最高隔离级别。读操作从不查看任何中间数据。

持久性

任何完成的操作都是持久的。所有可访问的数据也都是持久的数据。读从来不会返回没有持久化的数据。

线性一致性

线性一致性 (也被称为 Atomic Consistency 或者 External Consistency) 是介于 strict consistency/严格一致性和 sequential consistency/顺序一致性之间的一致性级别。

对于线性一致性, 假设每个操作从宽松的已同步全局时钟获取时间戳。如果并且仅当操作总是完成操作是线性化的

操作是线性的，如果并且仅当操作总是完成的好像他们是按顺序执行并且每个操作看上去以程序指定的顺序完成那样。

这句话翻译的好痛苦，还是看原文吧: Operations are linearized if and only if they always complete as though they were executed in a sequential order and each operation appears to complete in the order specified by the program.

同样的，如果操作的时间戳发生在其他操作前，这个操作在顺序上必须也发生在其他操作前。

例如，考虑客户端在时间点 t_1 完成一个写操作。客户端在 t_2 ($t_2 > t_1$)发送的读请求应该收到至少在上一次在 t_1 时间点完成的写之后最近的值。然后，读可能实际在 t_3 完成，而返回值，在 t_2 时刻开始读，可能在 t_3 时刻已经不再新鲜。

对于观察操作 `etcd` 不保证线性一致性。期望用户验证观察应答的修订版本来确保正确顺序。

对于所有其他操作 `etcd` 默认保证线性一致性。线性一致性会带来开销，无论如何，因为线性化请求必须通过Raft一致性过程。为了获得读请求更低的延迟和更高的吞吐量，客户端可以配置请求的一致性模型为 `serializable`，这可能访问不新鲜的数据(with respect to quorum)，但是移除了线性化访问时依赖活动一致性的性能损失。

etcd v3 认证设计

为什么不重用v2的认证系统？

v3 协议使用 gRPC 传输而不是像 v2 这样的 RESTful 接口。这个新协议提供了迭代和改进 v2 设计的机会。例如，v3 auth 具有基于连接的身份验证，而不是 v2 的每请求的速度较慢的认证。此外，在实践中，v2 auth 的语义在关于一致性的推理方面有些笨重，将在下一节中描述。对于 v3，认证机制有明确定义的描述和实现，可以修复 v2 认证系统的缺陷。

功能需求

- 每连接认证，而不是每请求
 - 基于用户 ID + 密码的认证，实现为 gRPC API
 - 在认证政策修改之后，认证必须刷新
- 功能应该和 v2 一样简单
 - v3 提供扁平键空间，和 v2 的目录结构不同。提供权限检查,如间隔匹配(as interval matching)
- 应该提供比 v2 认证更强的一致性保证

主要需要更改

- 客户端必须在发送被验证的请求之前创建仅用于认证的专用连接
- 添加权限信息(用户 ID 和 合法 revision) 到 Raft 命令
(`etcdserverpb.InternalRaftRequest`)
- 在状态机层做每个请求的权限检查，而不是在 API 层

权限元数据一致性

认证的元数据也应该在存储中存储和管理，该存储被 etcd 的 Raft 协议控制，和其他在 etcd 中的数据一样。要求不牺牲整个 etcd 集群的可用性和一致性。如果读取或写入元数据（例如权限信息）需要每个节点（超过法定人数）的同意，则单节点故障会让整个集群停止。要求所有节点立即同意意味着，如果任意集群成员宕机，即使群集具有可用的法定人数，检查普通的读/写请求也无法完成。这种全场一致方案最终会降低集群的可用性；从 raft 而来的基于法定人数的共识就足够了，因为合约遵循一致的顺序。

The authentication mechanism in the etcd v2 protocol has a tricky part because the metadata consistency should work as in the above, but does not: each permission check is processed by the etcd member that receives the client request

(etcdserver/api/v2http/client.go), including follower members. Therefore, it's possible the check may be based on stale metadata.

This staleness means that auth configuration cannot be reflected as soon as operators execute `etcdctl`. Therefore there is no way to know how long the stale metadata is active. Practically, the configuration change is reflected immediately after the command execution. However, in some cases of heavy load, the inconsistent state can be prolonged and it might result in counter-intuitive situations for users and developers. It requires a workaround like this: <https://github.com/coreos/etcd/pull/4317#issuecomment-179037582>

Inconsistent permissions are unsafe for linearized requests

Inconsistent authentication state is most serious for writes. Even if an operator disables write on a user, if the write is only ordered with respect to the key value store but not the authentication system, it's possible the write will complete successfully. Without ordering on both the auth store and the key-value store, the system will be susceptible to stale permission attacks.

Therefore, the permission checking logic should be added to the state machine of etcd. Each state machine should check the requests based on its permission information in the apply phase (so the auth information must not be stale).

Design and implementation

Authentication

At first, a client must create a gRPC connection only to authenticate its user ID and password. An etcd server will respond with an authentication reply. The response will be an authentication token on success or an error on failure. The client can use its authentication token to present its credentials to etcd when making API requests.

The client connection used to request the authentication token is typically thrown away; it cannot carry the new token's credentials. This is because gRPC doesn't provide a way for adding per RPC credential after creation of the connection (calling `grpc.Dial()`). Therefore, a client cannot assign a token to its connection that is obtained through the connection. The client needs a new connection for using the token.

Notes on the implementation of `Authenticate()` RPC

`Authenticate()` RPC generates an authentication token based on a given user name and password. etcd saves and checks a configured password and a given password using Go's `bcrypt` package. By design, `bcrypt`'s password checking mechanism is computationally expensive, taking nearly 100ms on an ordinary x64 server. Therefore, performing this check in the state machine apply phase would cause performance trouble: the entire etcd cluster can only serve almost 10 `Authenticate()` requests per second.

For good performance, the v3 auth mechanism checks passwords in etcd's API layer, where it can be parallelized outside of raft. However, this can lead to potential time-of-check/time-of-use (TOCTOU) permission lapses:

1. client A sends a request `Authenticate()`
2. the API layer processes the password checking part of `Authenticate()`
3. another client B sends a request of `ChangePassword()` and the server completes it
4. the state machine layer processes the part of getting a revision number for the `Authenticate()` from A
5. the server returns a success to A
6. now A is authenticated on an obsolete password

For avoiding such a situation, the API layer performs *version number validation* based on the revision number of the auth store. During password checking, the API layer saves the revision number of auth store. After successful password checking, the API layer compares the saved revision number and the latest revision number. If the numbers differ, it means someone else updated the auth metadata. So it retries the checking. With this mechanism, the successful password checking based on the obsolete password can be avoided.

Resolving a token in the API layer

After authenticating with `Authenticate()`, a client can create a gRPC connection as it would without auth. In addition to the existing initialization process, the client must associate the token with the newly created connection. `grpc.WithPerRPCCredentials()` provides the functionality for this purpose.

Every authenticated request from the client has a token. The token can be obtained with `grpc.metadata.FromIncomingContext()` in the server side. The server can obtain who is issuing the request and when the user was authorized. The information will be filled by the API layer in the header (`etcdserverpb.RequestHeader.Username` and `etcdserverpb.RequestHeader.AuthRevision`) of a raft log entry (`etcdserverpb.InternalRaftRequest`).

Checking permission in the state machine

The auth info in `etcdserverpb.RequestHeader` is checked in the apply phase of the state machine. This step checks the user is granted permission to requested keys on the latest revision of auth store.

Two types of tokens: simple and JWT

There are two kinds of token types: simple and JWT. The simple token isn't designed for production use cases. Its tokens aren't cryptographically signed and servers must statefully track token-user correspondence; it is meant for development testing. JWT tokens should be used for production deployments since it is cryptographically signed and verified. From the implementation perspective, JWT is stateless. Its token can include metadata including username and revision, so servers don't need to remember correspondence between tokens and the metadata.

Notes on the difference between KVS models and file system models

etcd v3 is a KVS, not a file system. So the permissions can be granted to the users in form of an exact key name or a key range like `["start key", "end key")`. It means that granting a permission of a nonexistent key is possible. Users should care about unintended permission granting. In a case of file system like system (e.g. Chubby or ZooKeeper), an inode like data structure can include the permission information. So granting permission to a nonexistent key won't be possible (except the case of sticky bits).

The etcd v3 model requires multiple lookup of the metadata unlike the file system like systems. The worst case lookup cost will be sum the user's total granted keys and intervals. The cost cannot be avoided because v3's flat key space is completely different from Unix's file system model (every inode includes permission metadata). Practically the cost won't be a serious problem because the metadata is small enough to benefit from caching.

核心 API 参考文档

前言

内容来自 ectd3 的 [API reference](#)。

原文内容是从 .proto 文件生成的，service和方法定义/message定义一起构成一个庞大的单页HTML文件，不利于阅读。因此在翻译时，遵循gitbook的习惯，按照服务/方法分开形成章节结构。

主要内容在 message 的字段定义上，翻译时没有复制原文中从 .proto 文件生成的表格，而是直接在 .proto 文件的 message 定义上翻译，感觉更直观一些。

内容

已经整理并翻译的内容：

- [KV service](#)
- [Watch service](#)
- [Lease service](#)

尚未完成的内容：

- service Cluster
- service Maintenance
- service Auth

KV service

KV service提供对键值对操作的支持。

在 rpc.proto 文件中 KV service 定义如下：

```
service KV {  
    // 从键值存储中获取范围内的key。  
    rpc Range(RangeRequest) returns (RangeResponse) {}  
  
    // 放置给定key到键值存储。  
    // put请求增加键值存储的修订版本并在事件历史中生成一个事件。  
    rpc Put(PutRequest) returns (PutResponse) {}  
  
    // 从键值存储中删除给定范围。  
    // 删除请求增加键值存储的修订版本并在事件历史中为每个被删除的key生成一个删除事件。  
    rpc DeleteRange(DeleteRangeRequest) returns (DeleteRangeResponse) {}  
  
    // 在单个事务中处理多个请求。  
    // 一个 txn 请求增加键值存储的修订版本并为每个完成的请求生成带有相同修订版本的事件。  
    // 不容许在一个txn中多次修改同一个key。  
    rpc Txn(TxnRequest) returns (TxnResponse) {}  
  
    // 压缩在etcd键值存储中的事件历史。  
    // 键值存储应该定期压缩，否则事件历史会无限制的持续增长。  
    rpc Compact(CompactionRequest) returns (CompactionResponse) {}  
}
```

Range方法

Range方法从键值存储中获取范围内的key.

```
rpc Range(RangeRequest) returns (RangeResponse) {}
```

注意: 没有操作单个key的方法，即使是存取单个key，也是需要使用 `Range` 方法的。

消息体

请求的消息体是 RangeRequest：

```
message RangeRequest {
  enum SortOrder {
    NONE = 0; // 默认，不排序
    ASCEND = 1; // 正序，低的值在前
    DESCEND = 2; // 倒序，高的值在前
  }
  enum SortTarget {
    KEY = 0;
    VERSION = 1;
    CREATE = 2;
    MOD = 3;
    VALUE = 4;
  }

  // key是 range 的第一个 key。如果 range_end 没有指定，请求仅查找这个key
  bytes key = 1;

  // range_end 是请求范围的上限 [key, range_end)
  // 如果 range_end 是 '\0'，范围是大于等于 key 的所有 key。
  // 如果 range_end 是 key 加一(例如, "aa"+1 == "ab", "a\xff"+1 == "b")，那么 range 请求
  // 获取以 key 为前缀的所有 key
  // 如果 key 和 range_end 都是'\0'，则 range 查询返回所有 key
  bytes range_end = 2;

  // 请求返回的 key 的数量限制。如果 limit 设置为0，则视为没有限制
  int64 limit = 3;

  // 修订版本是用于 range 的键值对存储的时间点。
  // 如果修订版本小于或等于零，range 是用在最新的键值对存储上。
  // 如果指定修订版本已经被压缩，返回 ErrCompacted 作为应答
  int64 revision = 4;

  // 指定返回结果的排序顺序
```

```
SortOrder sort_order = 5;

// 用于排序的键值字段
SortTarget sort_target = 6;

// 设置 range 请求使用串行化成员本地读(serializable member-local read)。
// range 请求默认是线性化的;线性化请求相比串行化请求有更高的延迟和低吞吐量,但是反映集群当前的一致性。
// 为了更好的性能,以可能脏读为交换,串行化范围请求在本地处理,无需和集群中的其他节点达到一致。
bool serializable = 7;

// keys_only 被设置时仅返回 key 而不需要 value
bool keys_only = 8;

// count_only 被设置时仅仅返回范围内 key 的数量
bool count_only = 9;

// min_mod_revision 是返回 key 的 mod revision 的下限;更低 mod revision 的所有 key 都将被过滤掉
int64 min_mod_revision = 10;

// max_mod_revision 是返回 key 的 mod revision 的上限;更高 mod revision 的所有 key 都将被过滤掉
int64 max_mod_revision = 11;

// min_create_revision 是返回 key 的 create revision 的下限;更低 create revision 的所有 key 都将被过滤掉
int64 min_create_revision = 12;

// max_create_revision 是返回 key 的 create revision 的上限;更高 create revision 的所有 key 都将被过滤掉
int64 max_create_revision = 13;
}
```

应答的消息体是 RangeResponse :

```
message RangeResponse {
  ResponseHeader header = 1;

  // kvs 是匹配 range 请求的键值对列表
  // 当 count 时是空的
  repeated mvccpb.KeyValue kvs = 2;

  // more 代表在被请求的范围内是否还有更多的 key
  bool more = 3;

  // count 被设置为在范围内的 key 的数量
  int64 count = 4;
}
```


`mvccpb.KeyValue` 来自 `kv.proto`，消息体定义为：

```
message KeyValue {
    // key 是 bytes 格式的 key。不容许 key 为空。
    bytes key = 1;

    // create_revision 是这个 key 最后一次创建的修订版本
    int64 create_revision = 2;

    // mod_revision 是这个 key 最后一次修改的修订版本
    int64 mod_revision = 3;

    // version 是 key 的版本。删除会重置版本为0, 而任何 key 的修改会增加它的版本。
    int64 version = 4;

    // value 是 key 持有的值, bytes 格式。
    bytes value = 5;

    // lease 是附加给 key 的租约 id。
    // 当附加的租约过期时, key 将被删除。
    // 如果 lease 为0, 则没有租约附加到 key。
    int64 lease = 6;
}
```

Put 方法

Put 方法设置指定 key 到键值存储。

Put 方法增加键值存储的修订版本并在事件历史中生成一个事件。

```
rpc Put(PutRequest) returns (PutResponse) {}
```

消息体

请求的消息体是 `PutRequest`：

```
message PutRequest {  
    // byte 数组形式的 key，用来保存到键值对存储  
    bytes key = 1;  
  
    // byte 数组形式的 value，在键值对存储中和 key 关联  
    bytes value = 2;  
  
    // 在键值存储中和 key 关联的租约id。0代表没有租约。  
    int64 lease = 3;  
  
    // 如果 prev_kv 被设置，etcd 获取改变之前的上一个键值对。  
    // 上一个键值对将在 put 应答中被返回  
    bool prev_kv = 4;  
  
    // 如果 ignore_value 被设置，etcd 使用它当前的 value 更新 key。  
    // 如果 key 不存在，返回错误。  
    bool ignore_value = 5;  
  
    // 如果 ignore_lease 被设置，etcd 使用它当前的租约更新 key。  
    // 如果 key 不存在，返回错误。  
    bool ignore_lease = 6;  
}
```

应答的消息体是 `PutResponse`：

```
message PutResponse {  
    ResponseHeader header = 1;  
  
    // 如果请求中的 prev_kv 被设置，将会返回上一个键值对  
    mvccpb.KeyValue prev_kv = 2;  
}
```


DeleteRange 方法

DeleteRange 方法从键值存储中删除给定范围。

删除请求增加键值存储的修订版本,并在事件历史中为每个被删除的 **key** 生成一个删除事件。

```
rpc DeleteRange(DeleteRangeRequest) returns (DeleteRangeResponse)
```

消息体

请求的消息体是 `DeleteRangeRequest` :

```
message DeleteRangeRequest {  
    // key是要删除的范围的第一个key  
    bytes key = 1;  
  
    // range_end 是要删除范围[key, range_end)的最后一个key  
    // 如果 range_end 没有给定，范围定义为仅包含 key 参数  
    // 如果 range_end 比给定的 key 大1，则 range 是以给定 key 为前缀的所有 key  
    // 如果 range_end 是 '\0'， 范围是所有大于等于参数 key 的所有 key。  
    bytes range_end = 2;  
  
    // 如果 prev_kv 被设置，etcd获取删除之前的上一个键值对。  
    // 上一个键值对将在 delete 应答中被返回  
    bool prev_kv = 3;  
}
```

应答的消息体是 `DeleteRangeResponse` :

```
message DeleteRangeResponse {  
    ResponseHeader header = 1;  
  
    // 被范围删除请求删除的 key 的数量  
    int64 deleted = 2;  
  
    // 如果请求中的 prev_kv 被设置，将会返回上一个键值对  
    repeated mvccpb.KeyValue prev_kvs = 3;  
}
```

Txn 方法

Txn 方法在单个事务中处理多个请求。

txn 请求增加键值存储的修订版本并为每个完成的请求生成带有相同修订版本的事件。

不容许在一个 txn 中多次修改同一个 key。

```
rpc Txn(TxnRequest) returns (TxnResponse) {}
```

背景

以下内容翻译来自 proto文件中 TxnRequest 的注释，解释了Txn请求的工作方式。

来自 google paxosdb 论文:

我们的实现围绕强大的我们称为 `MultiOp` 的原生(primitive)。除了游历外的所有其他数据库操作被实现为对 `MultiOp` 的单一调用。`MultiOp` 被原子执行并由三个部分组成：

1. 被称为 `guard` 的测试列表。在 `guard` 中每个测试检查数据库中的单个项。它可能检查某个值的存在或者缺失，或者和给定的值比较。在 `guard` 中两个不同的测试可能应用于数据库中相同或者不同的项。`guard` 中的所有测试被应用然后 `MultiOp` 返回结果。如果所有测试是 `true`，`MultiOp` 执行 `t` 操作 (见下面的第二项)，否则它执行 `f` 操作 (见下面的第三项)。
2. 被称为 `t` 操作的数据库操作列表。列表中的每个操作是插入，删除，或者查找操作，并应用到单个数据库项。列表中的两个不同操作可能应用到数据库中相同或者不同的项。如果 `guard` 评价为`true` 这些操作将被执行
3. 被成为 `f` 操作的数据库操作列表。类似 `t` 操作，但是是在 `guard` 评价为 `false` 时执行。

消息体

请求的消息体是 `TxnRequest`：

```
message TxnRequest {  
    // compare 是断言列表，体现为条件的联合。  
    // 如果比较成功，那么成功请求将被按顺序处理，而应答将按顺序包含他们对应的应答。  
    // 如果比较失败，那么失败请求将被按顺序处理，而应答将按顺序包含他们对应的应答。  
    repeated Compare compare = 1;  
  
    // 成功请求列表，当比较评估为 true 时将被应用。  
    repeated RequestOp success = 2;  
  
    // 失败请求列表，当比较评估为 false 时将被应用。  
    repeated RequestOp failure = 3;  
}
```

应答的消息体是 TxnResponse ：

```
message TxnResponse {  
    ResponseHeader header = 1;  
  
    // 如果比较评估为true则succeeded被设置为true，否则是false  
    bool succeeded = 2;  
  
    // 应答列表，如果 succeeded 是 true 则对应成功请求，如果 succeeded 是 false 则对应失败请求  
    repeated ResponseOp responses = 3;  
}
```

Compare 消息体：

```

message Compare {
    enum CompareResult {
        EQUAL = 0;
        GREATER = 1;
        LESS = 2;
        NOT_EQUAL = 3;
    }
    enum CompareTarget {
        VERSION = 0;
        CREATE = 1;
        MOD = 2;
        VALUE = 3;
    }

    // result 是这个比较的逻辑比较操作
    CompareResult result = 1;

    // target 是比较要检查的键值字段
    CompareTarget target = 2;

    // key 是用于比较操作的主题key
    bytes key = 3;

    oneof target_union {
        // version 是给定 key 的版本
        int64 version = 4;

        // create_revision 是给定 key 的创建修订版本
        int64 create_revision = 5;

        // mod_revision 是给定 key 的最后修改修订版本
        int64 mod_revision = 6;

        // value 是给定 key 的值，以 bytes 的形式
        bytes value = 7;
    }
}

```

RequestOp 消息体：

```

message RequestOp {
    // request 是可以被事务接受的请求类型的联合
    oneof request {
        RangeRequest request_range = 1;
        PutRequest request_put = 2;
        DeleteRangeRequest request_delete_range = 3;
    }
}

```

ResponseOp 消息体：

```
message ResponseOp {  
  // response 是事务返回的应答类型的联合  
  oneof response {  
    RangeResponse response_range = 1;  
    PutResponse response_put = 2;  
    DeleteRangeResponse response_delete_range = 3;  
  }  
}
```


Compact 方法

Compact 方法压缩 etcd 键值对存储中的事件历史。

键值对存储应该定期压缩，否则事件历史会无限制的持续增长。

```
rpc Compact(CompactionRequest) returns (CompactionResponse) {}
```

消息体

请求的消息体是 `CompactionRequest`，`CompactionRequest` 压缩键值对存储到给定修订版本。所有修订版本比压缩修订版本小的键都将被删除：

```
message CompactionRequest {  
    // 键值存储的修订版本，用于比较操作  
    int64 revision = 1;  
  
    // physical设置为 true 时 RPC 将会等待直到压缩物理性的应用到本地数据库，到这程度被压缩的项将完全  
    // 从后端数据库中移除。  
    bool physical = 2;  
}
```

应答的消息体是 `CompactionResponse`：

```
message CompactionResponse {  
    ResponseHeader header = 1;  
}
```

Watch service

Watch service提供观察键值对变化的支持。

在 rpc.proto 中 Watch service 定义如下：

```
service Watch {  
    // Watch 观察将要发生或者已经发生的事件。  
    // 输入和输出都是流;输入流用于创建和取消观察，而输出流发送事件。  
    // 一个观察 RPC 可以在一次性在多个key范围上观察，并为多个观察流化事件。  
    // 整个事件历史可以从最后压缩修订版本开始观察。  
    rpc Watch(stream WatchRequest) returns (stream WatchResponse) {}  
}
```

Watch 方法

WatchService 只有一个 `watch` 方法。

```
// Watch 观察将要发生或者已经发生的事件。  
// 输入和输出都是流;输入流用于创建和取消观察，而输出流发送事件。  
// 一个观察 RPC 可以在一次性在多个 key 范围上观察，并为多个观察流化事件。  
// 整个事件历史可以从最后压缩修订版本开始观察。  
rpc Watch(stream WatchRequest) returns (stream WatchResponse) {}
```

消息定义

请求的消息体是 `WatchRequest`：

```
message WatchRequest {  
  // request_union 要么是创建新的观察者的请求，要么是取消一个已经存在的观察者的请求  
  oneof request_union {  
    WatchCreateRequest create_request = 1;  
    WatchCancelRequest cancel_request = 2;  
  }  
}
```

创建新的观察者的请求 `WatchCreateRequest`：

```
message WatchCreateRequest {
    // key 是注册要观察的 key
    bytes key = 1;

    // range_end 是要观察的范围 [key, range_end) 的终点。
    // 如果 range_end 没有设置，则只有参数 key 被观察。
    // 如果 range_end 等同于 '\0'， 则大于等于参数 key 的所有 key 都将被观察
    // 如果 range_end 比给定 key 大1， 则所有以给定 key 为前缀的 key 都将被观察
    bytes range_end = 2;

    // start_revision 是可选的开始(包括)观察的修订版本。不设置 start_revision 则表示 "现在".
    int64 start_revision = 3;

    // 设置 progress_notify，这样如果最近没有事件，etcd 服务器将定期的发送不带任何事件的 WatchResponse 给新的观察者。
    // 当客户端希望从最近已知的修订版本开始恢复断开的观察者时有用。
    // etcd 服务器将基于当前负载决定它发送通知的频率。
    bool progress_notify = 4;

    enum FilterType {
        // 过滤掉 put 事件
        NOPUT = 0;

        // 过滤掉 delete 事件
        NODELETE = 1;
    }

    // 过滤器，在服务器端发送事件给回观察者之前，过滤掉事件。
    repeated FilterType filters = 5;

    // 如果 prev_kv 被设置，被创建的观察者在事件发生前获取上一次的KV。
    // 如果上一次的KV已经被压缩，则不会返回任何东西
    bool prev_kv = 6;
}
```

取消已有观察者的 `WatchCancelRequest`：

```
message WatchCancelRequest {
    // watch_id 是要取消的观察者的id，这样就不再有更多事件传播过来了。
    int64 watch_id = 1;
}
```

应答的消息体 `WatchResponse`：

```

message WatchResponse {
    ResponseHeader header = 1;
    // watch_id 是和应答相关的观察者的ID
    int64 watch_id = 2;

    // 如果应答是用于创建观察者请求的，则 created 设置为 true。
    // 客户端应该记录 watch_id 并期待从同样的流中为创建的观察者接收事件。
    // 所有发送给被创建的观察者的事件将附带同样的 watch_id
    bool created = 3;

    // 如果应答是用于取消观察者请求的，则 canceled 设置为true。
    // 不会再有事件发送给被取消的观察者。
    bool canceled = 4;

    // compact_revision 被设置为最小 index，如果观察者试图观察被压缩的 index。
    // 当在被压缩的修订版本上创建观察者或者观察者无法追上键值对存储的进展时发生。
    // 客户端应该视观察者为被取消，并不应该试图再次创建任何带有相同 start_revision 的观察者。
    int64 compact_revision = 5;

    // cancel_reason 指出取消观察者的理由。
    string cancel_reason = 6;

    repeated mvccpb.Event events = 11;
}

```

mvccpb.Event 的消息体：

```

message Event {
    enum EventType {
        PUT = 0;
        DELETE = 1;
    }

    // type 是事件的类型。
    // 如果类型是 PUT，表明新的数据已经存储到 key。
    // 如果类型是 DELETE，表明 key 已经被删除。
    EventType type = 1;

    // kv 为事件持有 KeyValue。
    // PUT 事件包含当前的kv键值对
    // kv.Version=1 的 PUT 事件表明 key 的创建
    // DELETE/EXPIRE 事件包含被删除的 key，它的修改修订版本设置为删除的修订版本
    KeyValue kv = 2;

    // prev_kv 持有在事件发生前的键值对
    KeyValue prev_kv = 3;
}

```


Lease service

Lease service 提供租约的支持。

在 `rpc.proto` 文件中 Lease service 定义如下：

```
service Lease {  
    // LeaseGrant 创建一个租约，当服务器在给定 time to live 时间内没有接收到 keepAlive 时租约过期。  
  
    // 如果租约过期则所有附加在租约上的key将过期并被删除。  
    // 每个过期的key在事件历史中生成一个删除事件。  
    rpc LeaseGrant(LeaseGrantRequest) returns (LeaseGrantResponse) {}  
  
    // LeaseRevoke 撤销一个租约。  
    // 所有附加到租约的key将过期并被删除。  
    rpc LeaseRevoke(LeaseRevokeRequest) returns (LeaseRevokeResponse) {}  
  
    // LeaseKeepAlive 通过从客户端到服务器端的流化的 keep alive 请求和从服务器端到客户端的流化的 keep alive 应答来维持租约。  
    rpc LeaseKeepAlive(stream LeaseKeepAliveRequest) returns (stream LeaseKeepAliveResponse) {}  
  
    // LeaseTimeToLive 获取租约信息。  
    rpc LeaseTimeToLive(LeaseTimeToLiveRequest) returns (LeaseTimeToLiveResponse) {}  
}
```

LeaseGrant 方法

LeaseGrant 方法创建一个租约。

```
rpc LeaseGrant(LeaseGrantRequest) returns (LeaseGrantResponse) {}
```

消息体

请求的消息体是 `LeaseGrantRequest` ：

```
message LeaseGrantRequest {  
    // TTL 是建议的以秒为单位的 time-to-live  
    int64 TTL = 1;  
  
    // ID 是租约的请求ID。如果ID设置为0，则出租人(也就是etcd server)选择一个ID。  
    int64 ID = 2;  
}
```

应答的消息体是 `LeaseGrantResponse` ：

```
message LeaseGrantResponse {  
    ResponseHeader header = 1;  
    // ID 是承认的租约的ID  
    int64 ID = 2;  
    // TTL 是服务器选择的以秒为单位的租约time-to-live  
    int64 TTL = 3;  
    string error = 4;  
}
```


LeaseRevoke 方法

LeaseRevoke 方法取消一个租约。

```
rpc LeaseRevoke(LeaseRevokeRequest) returns (LeaseRevokeResponse) {}
```

消息体

请求的消息体是 `LeaseRevokeRequest`：

```
message LeaseRevokeRequest {  
    // ID是要取消的租约的ID。  
    // 当租约被取消时，所有关联的key将被删除  
    int64 ID = 1;  
}
```

应答的消息体是 `LeaseRevokeResponse`：

```
message LeaseRevokeResponse {  
    ResponseHeader header = 1;  
}
```

LeaseKeepAlive 方法

LeaseKeepAlive 方法维持一个租约。

```
rpc LeaseKeepAlive(stream LeaseKeepAliveRequest) returns (stream LeaseKeepAliveResponse) {}
```

消息体

请求的消息体是 `LeaseKeepAliveRequest`：

```
message LeaseKeepAliveRequest {  
    // ID 是要继续存活的租约的 ID  
    int64 ID = 1;  
}
```

应答的消息体是 `LeaseKeepAliveResponse`：

```
message LeaseKeepAliveResponse {  
    ResponseHeader header = 1;  
    // ID 是从继续存活请求中得来的租约 ID  
    int64 ID = 2;  
    // TTL是租约新的 time-to-live  
    int64 TTL = 3;  
}
```

LeaseTimeToLive 方法

LeaseTimeToLive 方法获取租约的信息.

```
rpc LeaseTimeToLive(LeaseTimeToLiveRequest) returns (LeaseTimeToLiveResponse) {}
```

消息体

请求的消息体是 `LeaseTimeToLiveRequest` :

```
message LeaseTimeToLiveRequest {  
    // ID 是租约的 ID.  
    int64 ID = 1;  
    // keys 设置为 true 可以查询附加到这个租约上的所有 key  
    bool keys = 2;  
}
```

应答的消息体是 `LeaseTimeToLiveResponse` :

```
message LeaseTimeToLiveResponse {  
    ResponseHeader header = 1;  
    // ID 是来自请求的 ID.  
    int64 ID = 2;  
    // TTL 是租约剩余的 TTL，单位为秒；租约将在接下来的 TTL + 1 秒之后过期  
    int64 TTL = 3;  
    // GrantedTTL 是租约创建/续约时初始授予的时间，单位为秒  
    int64 grantedTTL = 4;  
    // keys 是附加到这个租约的 key 的列表  
    repeated bytes keys = 5;  
}
```

并发 **API** 参考文档

前言

内容来自官网的 [etcd concurrency API Reference](#)。

类似核心 API 参考文档，我们在翻译时没有复制原文中从 `.proto` 文件生成的表格，而是直接在 `.proto` 文件的 `message` 定义上翻译。

内容

已经整理并翻译的内容：

- [Lock service](#)
- [Election service](#)

Lock service

Lock service 提供分布式共享锁的支持。

在 `v3lock.proto` 中 Lock service 定义如下：

```
// Lock service 以 gRPC 接口的方式暴露客户端锁机制。
service Lock {
  // 在给定命令锁上获得分布式共享锁。
  // 成功时，将返回一个唯一 key，在调用者持有锁期间会一直存在。
  // 这个 key 可以和事务一起工作，以安全的确保对 etcd 的更新仅仅发生在持有锁时。
  // 锁被持有直到在 key 上调用解锁或者和所有者关联的租约过期。
  rpc Lock(LockRequest) returns (LockResponse) {}

  // Unloke 使用 Lock 返回的 key 并释放对锁的持有。
  // 下一个在等待这个锁的 Lock 的调用者将被唤醒并给予锁的所有权。
  rpc Unlock(UnlockRequest) returns (UnlockResponse) {}
}
```

Lock 方法

Lock service 的 `Lock` 方法。

```
// 在给定命令锁上获得分布式共享锁。  
// 成功时，将返回一个唯一 key，在调用者持有锁期间会一直存在。  
// 这个 key 可以和事务一起工作，以安全的确保对 etcd 的更新仅仅发生在持有锁时。  
// 锁被持有直到在 key 上调用解锁或者和所有者关联的租约过期。  
rpc Lock(LockRequest) returns (LockResponse) {}
```

消息定义

请求的消息体是 `LockRequest`：

```
message LockRequest {  
    // name 是要获取的分布式共享锁的标识  
    bytes name = 1;  
    // lease 是要附加到锁所有权的租约的 ID。如果租约过期或者撤销时正持有锁，则锁将自动释放。  
    // 使用相同的租约调用锁将视为单次获取；使用同样租约的第二次锁定将是空操作。  
    int64 lease = 2;  
}
```

应答的信息体是 `LockResponse`：

```
message LockResponse {  
    etcdserverpb.ResponseHeader header = 1;  
    // key 是在 Lock 调用者拥有锁期间存在于 etcd 上的 key。  
    // 用户不可以修改这个 key，否则锁将不能正常工作  
    bytes key = 2;  
}
```

Unloke 方法

Lock service 的 `Unloke` 方法。

```
// Unloke 使用 Lock 返回的 key 并释放对锁的持有。  
// 下一个在等待这个锁的 Lock 的调用者将被唤醒并给予锁的所有权。  
rpc Unlock(UnlockRequest) returns (UnlockResponse) {}
```

消息定义

请求的消息体是 `UnlockRequest`：

```
message UnlockRequest {  
    // key 是通过 Lock 方法得到的锁所有权 key  
    bytes key = 1;  
}
```

应答的消息体是 `UnlockResponse`：

```
message UnlockResponse {  
    etcdserverpb.ResponseHeader header = 1;  
}
```

Election service

Election service 提供观察键值对变化的支持。

在 `v3election.proto` 中 Election service 定义如下：

```
// Election service 以 gRPC 接口的方式暴露客户端选举机制。
service Election {
  // Campaign 等待获得选举的领导地位，如果成功返回 LeaderKey 代表领导地位。
  // 然后 LeaderKey 可以用来在选举时发起新的值，在依然持有领导地位时事务性的守护 API 请求，
  // 还有从选举中辞职。
  rpc Campaign(CampaignRequest) returns (CampaignResponse) {}

  // Proclaim 用新值更新领导者的旧值
  rpc Proclaim(ProclaimRequest) returns (ProclaimResponse) {}

  // Leader 返回当前的选举公告，如果有。
  rpc Leader(LeaderRequest) returns (LeaderResponse) {}

  // Observe 以流的方式返回选举公告，和被选举的领导者发布的顺序一致。
  rpc Observe(LeaderRequest) returns (stream LeaderResponse) {}

  // Resign 放弃选举领导地位，以便其他参选人可以在选举中获得领导地位。
  rpc Resign(ResignRequest) returns (ResignResponse) {}
}
```


Campaign 方法

Campaign 方法用于参加选举以期获得领导地位：

```
// Campaign 等待获得选举的领导地位，如果成功返回 LeaderKey 代表领导地位。  
// 然后 LeaderKey 可以用来在选举时发起新的值，在依然持有领导地位时事务性的守护 API 请求，  
// 还有从选举中辞职。  
rpc Campaign(CampaignRequest) returns (CampaignResponse) {}
```

消息定义

请求的消息体是 CampaignRequest：

```
message CampaignRequest {  
    // name 是选举的标识符，用来参加竞选  
    bytes name = 1;  
    // lease is the ID of the lease attached to leadership of the election. If the  
    // lease expires or is revoked before resigning leadership, then the  
    // leadership is transferred to the next campaigner, if any.  
    // lease 是附加到选举领导地位的租约的ID。如果租约过期或者在放弃领导地位之前取消，  
    // 则领导地位转移到下一个竞选者，如果有。  
    int64 lease = 2;  
    // value 是竞选者赢得选举时设置的初始化公告值。  
    bytes value = 3;  
}
```

应答的消息体是 CampaignResponse：

```
message CampaignResponse {  
    etcdserverpb.ResponseHeader header = 1;  
    // leader 描述用于持有选举的领导地位的资源  
    LeaderKey leader = 2;  
}
```

LeaderKey 消息体的内容：

```
message LeaderKey {  
    // name 是选举标识符，和领导地位 key 对应  
    bytes name = 1;  
    // key 是不透明的 key ，代表选举的领导地位。  
    // 如果 key 被删除，则领导地位丢失  
    bytes key = 2;  
    // rev 是 key 的创建修订版本。它可以用来在事务期间测验选举的领导地位，通过测验 key 的创建修订版本  
    // 匹配 rev  
    int64 rev = 3;  
    // lease 是选举领导者的租约 ID  
    int64 lease = 4;  
}
```

Proclaim 方法

Proclaim 方法用于更新值：

```
// Proclaim 用新值更新领导者的旧值  
rpc Proclaim(ProclaimRequest) returns (ProclaimResponse) {}
```

消息定义

请求的消息体是 `ProclaimRequest`：

```
message ProclaimRequest {  
    // leader 是在选举上持有的领导地位  
    LeaderKey leader = 1;  
    // value 是打算用于覆盖领导者当前值的更新。  
    bytes value = 2;  
}
```

应答的消息体是 `ProclaimResponse`：

```
message ProclaimResponse {  
    etcdserverpb.ResponseHeader header = 1;  
}
```

Leader 方法

Leader 方法用于信息查询：

```
// Leader 返回当前的选举公告，如果有。  
rpc Leader(LeaderRequest) returns (LeaderResponse) {}
```

消息定义

请求的消息体是 `LeaderRequest`：

```
message LeaderRequest {  
    // name 是选举标识符, 用于查询领导地位信息的  
    bytes name = 1;  
}
```

应答的消息体是 `LeaderResponse`：

```
message LeaderResponse {  
    etcdserverpb.ResponseHeader header = 1;  
    // kv 是键值对，体现最后的领导者更新  
    mvccpb.KeyValue kv = 2;  
}
```

`mvccpb.KeyValue` 来自 `kv.proto`，消息体定义为：

```
message KeyValue {  
    // key 是 bytes 格式的 key。不容许 key 为空。  
    bytes key = 1;  
  
    // create_revision 是这个 key 最后一次创建的修订版本  
    int64 create_revision = 2;  
  
    // mod_revision 是这个 key 最后一次修改的修订版本  
    int64 mod_revision = 3;  
  
    // version 是 key 的版本。删除会重置版本为0,而任何 key 的修改会增加它的版本。  
    int64 version = 4;  
  
    // value 是 key 持有的值,bytes 格式。  
    bytes value = 5;  
  
    // lease 是附加给 key 的租约 id。  
    // 当附加的租约过期时,key 将被删除。  
    // 如果 lease 为0,则没有租约附加到 key。  
    int64 lease = 6;  
}
```

Observe 方法

Observe 方法是 Leader 方法的 stream 形式：

```
// Observe 以流的方式返回选举公告，和被选举的领导者发布的顺序一致。  
rpc Observe(LeaderRequest) returns (stream LeaderResponse) {}
```

消息定义

消息体和Leader方法相同，都是 `LeaderRequest` 和 `LeaderResponse` 。

Resign 方法

Leader 方法用于放弃选举领导地位：

```
// Resign 放弃选举领导地位，以便其他参选人可以在选举中获得领导地位。  
rpc Resign(ResignRequest) returns (ResignResponse) {}
```

消息定义

请求的消息体是 `ResignRequest`：

```
message ResignRequest {  
    // leader 是要放弃的领导地位  
    LeaderKey leader = 1;  
}
```

应答的消息体是 `ResignResponse`：

```
message ResignResponse {  
    etcdserverpb.ResponseHeader header = 1;  
}
```

Tags